May 1, 2023

TP Machine Learning INSA LYON

Le but du TP est de prédire les prix de maisons en fonction de différentes variables

0.1 Importation des libraries à utiliser

[130]:
```
import datetime as dt
import pandas as pd
import numpy as np
#Libraries for data visualization
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error
from sklearn.metrics import r2_score
from sklearn.linear_model import Ridge
from sklearn.linear_model import Lasso
from sklearn.model_selection import GridSearchCV
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import make_pipeline
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import KFold
from sklearn.metrics import explained_variance_score
```

[131]:
```
import warnings
warnings.filterwarnings('ignore')
```

0.2 Visualisation générale des données

0.2.1 Read csv file

[132]:
```
df = pd.read_csv('kc_house_data.csv')
```

0.2.2 Affichages des 5 premières lignes du dataset

[133]:
```
df.head()
```

[133]:

	id	date	price	bedrooms	bathrooms	sqft_living	sqft_lot	floors	waterfront	view	…	grade	sqft_above	sqft_basement	yr_built	yr_renovated	zipcode	lat	long	sqft_living15	sqft_lot15
0	7129300520	20141013T000000	221900.0	3	1.00	1180	5650	1.0	0	0	…	7	1180	0	1955	0	98178	47.5112	-122.257	1340	5650
1	6414100192	20141209T000000	538000.0	3	2.25	2570	7242	2.0	0	0	…	7	2170	400	1951	1991	98125	47.7210	-122.319	1690	7639
2	5631500400	20150225T000000	180000.0	2	1.00	770	10000	1.0	0	0	…	6	770	0	1933	0	98028	47.7379	-122.233	2720	8062
3	2487200875	20141209T000000	604000.0	4	3.00	1960	5000	1.0	0	0	…	7	1050	910	1965	0	98136	47.5208	-122.393	1360	5000
4	1954400510	20150218T000000	510000.0	3	2.00	1680	8080	1.0	0	0	…	8	1680	0	1987	0	98074	47.6168	-122.045	1800	7503

[5 rows x 21 columns]

0.2.3 Describe pour visualiser les données avec pandas

[134]:
```
df.info()
#Visualize the data that is in the csv
df.describe()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 21613 entries, 0 to 21612
Data columns (total 21 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
 0   id             21613 non-null  int64
 1   date           21613 non-null  object
 2   price          21613 non-null  float64
 3   bedrooms       21613 non-null  int64
 4   bathrooms      21613 non-null  float64
 5   sqft_living    21613 non-null  int64
 6   sqft_lot       21613 non-null  int64
 7   floors         21613 non-null  float64
 8   waterfront     21613 non-null  int64
 9   view           21613 non-null  int64
 10  condition      21613 non-null  int64
 11  grade          21613 non-null  int64
 12  sqft_above     21613 non-null  int64
 13  sqft_basement  21613 non-null  int64
 14  yr_built       21613 non-null  int64
 15  yr_renovated   21613 non-null  int64
 16  zipcode        21613 non-null  int64
 17  lat            21613 non-null  float64
 18  long           21613 non-null  float64
 19  sqft_living15  21613 non-null  int64
 20  sqft_lot15     21613 non-null  int64
dtypes: float64(5), int64(15), object(1)
memory usage: 3.5+ MB
```

[134]:

	id	price	bedrooms	bathrooms	sqft_living	\
count	2.161300e+04	2.161300e+04	21613.000000	21613.000000	21613.000000	
mean	4.580302e+09	5.400881e+05	3.370842	2.114757	2079.899736	
std	2.876566e+09	3.671272e+05	0.930062	0.770163	918.440897	
min	1.000102e+06	7.500000e+04	0.000000	0.000000	290.000000	
25%	2.123049e+09	3.219500e+05	3.000000	1.750000	1427.000000	
50%	3.904930e+09	4.500000e+05	3.000000	2.250000	1910.000000	
75%	7.308900e+09	6.450000e+05	4.000000	2.500000	2550.000000	
max	9.900000e+09	7.700000e+06	33.000000	8.000000	13540.000000	

	sqft_lot	floors	waterfront	view	condition	\
count	2.161300e+04	21613.000000	21613.000000	21613.000000	21613.000000	
mean	1.510697e+04	1.494309	0.007542	0.234303	3.409430	

```
std    4.142051e+04      0.539989      0.086517      0.766318      0.650743
min    5.200000e+02      1.000000      0.000000      0.000000      1.000000
25%    5.040000e+03      1.000000      0.000000      0.000000      3.000000
50%    7.618000e+03      1.500000      0.000000      0.000000      3.000000
75%    1.068800e+04      2.000000      0.000000      0.000000      4.000000
max    1.651359e+06      3.500000      1.000000      4.000000      5.000000

              grade    sqft_above  sqft_basement      yr_built  yr_renovated  \
count  21613.000000  21613.000000   21613.000000  21613.000000  21613.000000
mean       7.656873   1788.390691     291.509045   1971.005136     84.402258
std        1.175459    828.090978     442.575043     29.373411    401.679240
min        1.000000    290.000000       0.000000   1900.000000      0.000000
25%        7.000000   1190.000000       0.000000   1951.000000      0.000000
50%        7.000000   1560.000000       0.000000   1975.000000      0.000000
75%        8.000000   2210.000000     560.000000   1997.000000      0.000000
max       13.000000   9410.000000    4820.000000   2015.000000   2015.000000

             zipcode           lat          long  sqft_living15     sqft_lot15
count  21613.000000  21613.000000  21613.000000   21613.000000   21613.000000
mean   98077.939805     47.560053   -122.213896    1986.552492   12768.455652
std       53.505026      0.138564      0.140828     685.391304   27304.179631
min    98001.000000     47.155900   -122.519000     399.000000     651.000000
25%    98033.000000     47.471000   -122.328000    1490.000000    5100.000000
50%    98065.000000     47.571800   -122.230000    1840.000000    7620.000000
75%    98118.000000     47.678000   -122.125000    2360.000000   10083.000000
max    98199.000000     47.777600   -121.315000    6210.000000  871200.000000
```

[135]:
```
df.isnull().sum()
```

[135]:
```
id               0
date             0
price            0
bedrooms         0
bathrooms        0
sqft_living      0
sqft_lot         0
floors           0
waterfront       0
view             0
condition        0
grade            0
sqft_above       0
sqft_basement    0
yr_built         0
yr_renovated     0
zipcode          0
lat              0
```

```
long             0
sqft_living15    0
sqft_lot15       0
dtype: int64
```

On constate qu'aucune variable ne contient de valeur nulle.

0.3 Visualisation par variable - On utilise pyplot pour afficher des infos utiles sur nos données

Pour chaque variable on affiche un histogramme pour en apprendre plus sur les variables

0.3.1 Price info

[136]:
```
plt.figure(figsize=(20,10))
plt.hist(df['price'], bins=300, color='green')
plt.xlabel('Price')
plt.ylabel('Number of houses')
plt.show()
```

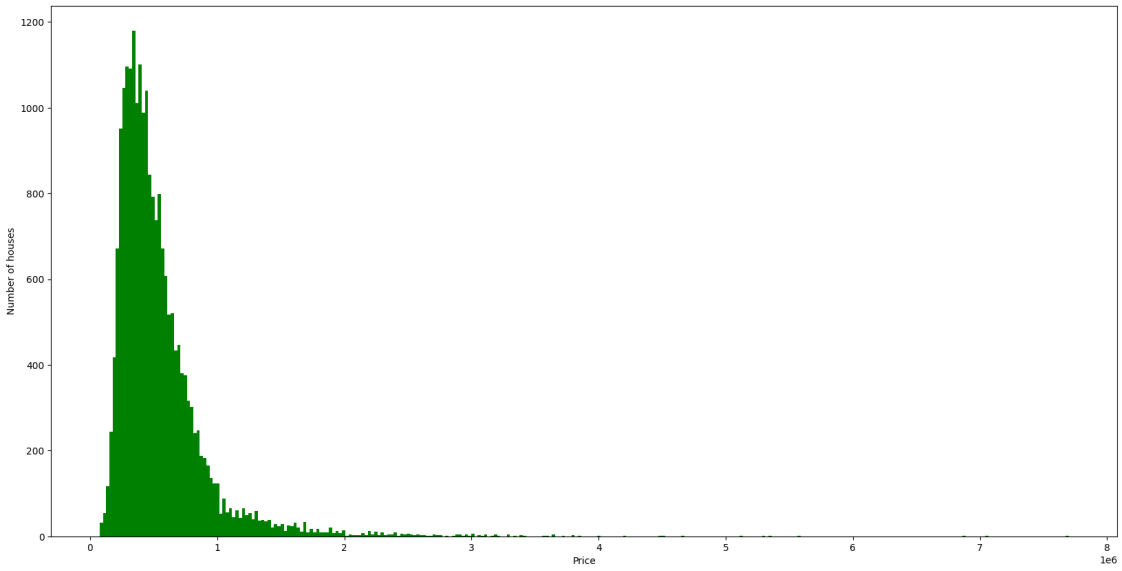

[137]:
```
#price describe
df['price'].describe()
```

[137]:
```
count    2.161300e+04
mean     5.400881e+05
std      3.671272e+05
min      7.500000e+04
25%      3.219500e+05
50%      4.500000e+05
```

```
75%       6.450000e+05
max       7.700000e+06
Name: price, dtype: float64
```

La distribution des prix est normale.

0.3.2 Bedrooms info

[138]:
```
plt.figure(figsize=(20,10))
plt.hist(df['bedrooms'], bins=100, color='green')
plt.xlabel('bedrooms')
plt.ylabel('Number of houses')
plt.show()
```

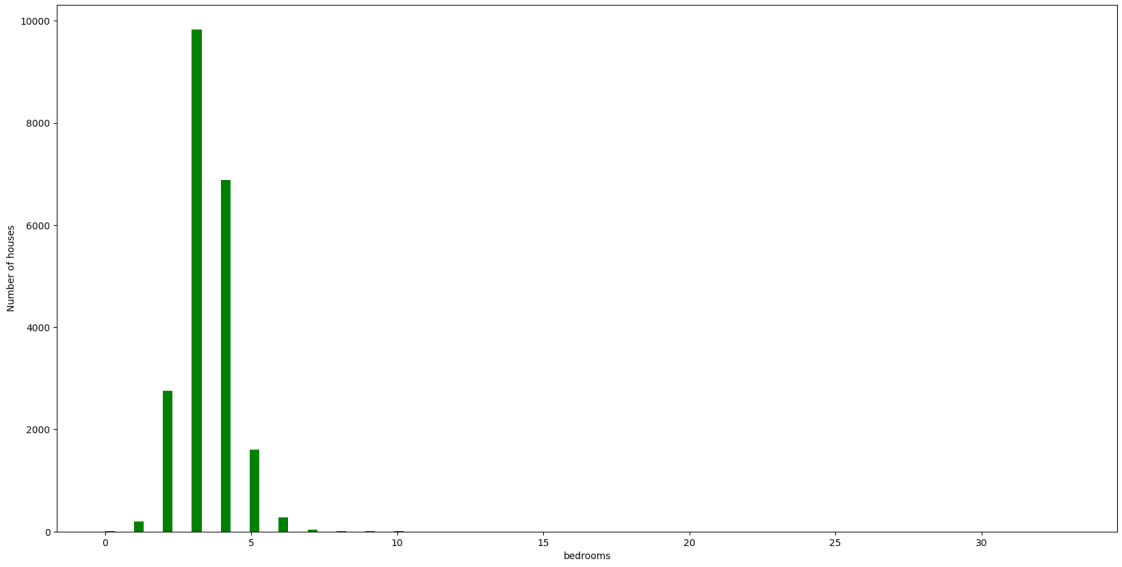

[139]:
```
df['bedrooms'].describe()
```

[139]:
```
count    21613.000000
mean         3.370842
std          0.930062
min          0.000000
25%          3.000000
50%          3.000000
75%          4.000000
max         33.000000
Name: bedrooms, dtype: float64
```

[140]:
```
df['bedrooms'].value_counts()
```

[140]:
```
3     9824
4     6882
2     2760
5     1601
6      272
1      199
7       38
0       13
8       13
9        6
10       3
11       1
33       1
Name: bedrooms, dtype: int64
```

[141]:
```
# print info on the row with 33 bedrooms
df[df['bedrooms'] == 33]
```

[141]:

	id	date	price	bedrooms	bathrooms	…
15870	2402100895	20140625T000000	640000.0	33	1.75	…

	sqft_living	sqft_lot	floors	waterfront	view	…	grade
15870	1620	6000	1.0	0	0	…	7

	sqft_above	sqft_basement	yr_built	yr_renovated	zipcode	lat
15870	1040	580	1947	0	98103	47.6878

	long	sqft_living15	sqft_lot15
15870	-122.331	1330	4700

[1 rows x 21 columns]

[142]:
```
df[df['bedrooms'] == 11]
```

[142]:

	id	date	price	bedrooms	bathrooms	sqft_living
8757	1773100755	20140821T000000	520000.0	11	3.0	3000

	sqft_lot	floors	waterfront	view	…	grade	sqft_above
8757	4960	2.0	0	0	…	7	2400

	sqft_basement	yr_built	yr_renovated	zipcode	lat	long
8757	600	1918	1999	98106	47.556	-122.363

	sqft_living15	sqft_lot15
8757	1420	4960

[1 rows x 21 columns]

[143]:
```
df[df['bedrooms'] == 0]
#id 6994 valeur abérante
```

[143]:

	id	date	price	bedrooms	bathrooms	\
875	6306400140	20140612T000000	1095000.0	0	0.00	
3119	3918400017	20150205T000000	380000.0	0	0.00	
3467	1453602309	20140805T000000	288000.0	0	1.50	
4868	6896300380	20141002T000000	228000.0	0	1.00	
6994	2954400190	20140624T000000	1295650.0	0	0.00	
8477	2569500210	20141117T000000	339950.0	0	2.50	
8484	2310060040	20140925T000000	240000.0	0	2.50	
9773	3374500520	20150429T000000	355000.0	0	0.00	
9854	7849202190	20141223T000000	235000.0	0	0.00	
12653	7849202299	20150218T000000	320000.0	0	2.50	
14423	9543000205	20150413T000000	139950.0	0	0.00	
18379	1222029077	20141029T000000	265000.0	0	0.75	
19452	3980300371	20140926T000000	142000.0	0	0.00	

	sqft_living	sqft_lot	floors	waterfront	view	…	grade	\
875	3064	4764	3.5	0	2	…	7	
3119	1470	979	3.0	0	2	…	8	
3467	1430	1650	3.0	0	0	…	7	
4868	390	5900	1.0	0	0	…	4	
6994	4810	28008	2.0	0	0	…	12	
8477	2290	8319	2.0	0	0	…	8	
8484	1810	5669	2.0	0	0	…	7	
9773	2460	8049	2.0	0	0	…	8	
9854	1470	4800	2.0	0	0	…	7	
12653	1490	7111	2.0	0	0	…	7	
14423	844	4269	1.0	0	0	…	7	
18379	384	213444	1.0	0	0	…	4	
19452	290	20875	1.0	0	0	…	1	

	sqft_above	sqft_basement	yr_built	yr_renovated	zipcode	lat	\
875	3064	0	1990	0	98102	47.6362	
3119	1470	0	2006	0	98133	47.7145	
3467	1430	0	1999	0	98125	47.7222	
4868	390	0	1953	0	98118	47.5260	
6994	4810	0	1990	0	98053	47.6642	
8477	2290	0	1985	0	98042	47.3473	
8484	1810	0	2003	0	98038	47.3493	
9773	2460	0	1990	0	98031	47.4095	
9854	1470	0	1996	0	98065	47.5265	
12653	1490	0	1999	0	98065	47.5261	
14423	844	0	1913	0	98001	47.2781	
18379	384	0	2003	0	98070	47.4177	
19452	290	0	1963	0	98024	47.5308	

```
          long  sqft_living15  sqft_lot15
875    -122.322           2360        4000
3119   -122.356           1470        1399
3467   -122.290           1430        1650
4868   -122.261           2170        6000
6994   -122.069           4740       35061
8477   -122.151           2500        8751
8484   -122.053           1810        5685
9773   -122.168           2520        8050
9854   -121.828           1060        7200
12653  -121.826           1500        4675
14423  -122.250           1380        9600
18379  -122.491           1920      224341
19452  -121.888           1620       22850

[13 rows x 21 columns]
```

On remarque que des maisons ont 0 et 33 chambres, ce sont des valeurs aberrantes que nous nettoierons.

0.3.3 Bathrooms info

[144]:
```
plt.figure(figsize=(20,10))
plt.hist(df['bathrooms'], bins=100, color='green')
plt.xlabel('bathrooms')
plt.ylabel('Number of houses')
plt.show()
```

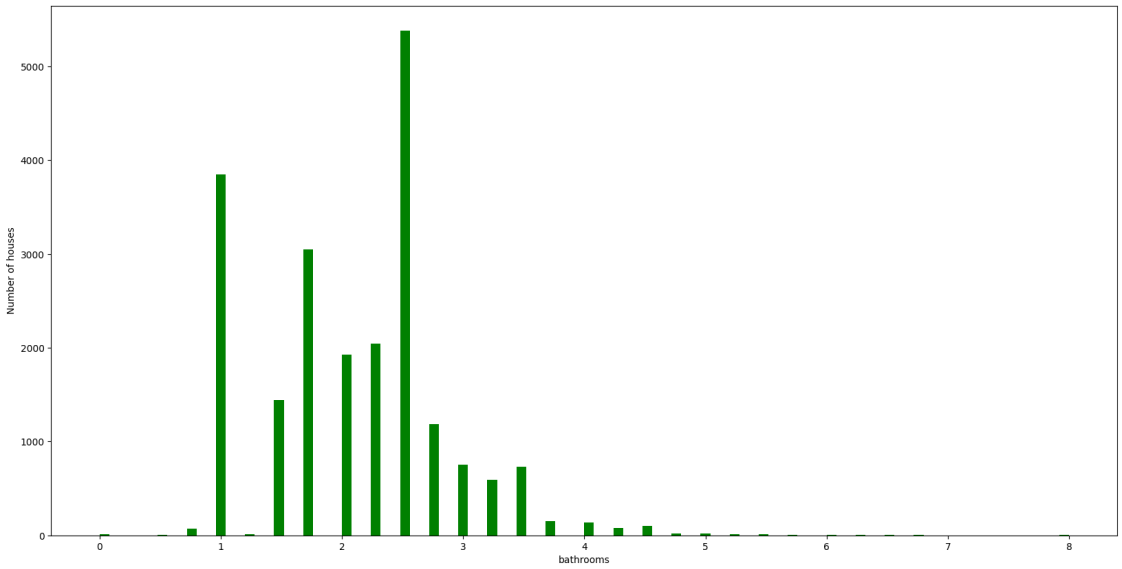

[145]:
```
#print info about bathrooms
df['bathrooms'].describe()
```

[145]:
```
count    21613.000000
mean         2.114757
std          0.770163
min          0.000000
25%          1.750000
50%          2.250000
75%          2.500000
max          8.000000
Name: bathrooms, dtype: float64
```

[146]:
```
df['bathrooms'].value_counts()
```

[146]:
```
2.50    5380
1.00    3852
1.75    3048
2.25    2047
2.00    1930
1.50    1446
2.75    1185
3.00     753
3.50     731
3.25     589
3.75     155
4.00     136
4.50     100
4.25      79
0.75      72
4.75      23
5.00      21
5.25      13
0.00      10
5.50      10
1.25       9
6.00       6
0.50       4
5.75       4
6.75       2
8.00       2
6.25       2
6.50       2
7.50       1
7.75       1
Name: bathrooms, dtype: int64
```

[147]:
```
#Show the line where bathrooms is 8
df[df['bathrooms'] == 8]
```

[147]:

	id	date	price	bedrooms	bathrooms	\
7252	6762700020	20141013T000000	7700000.0	6	8.0	
12777	1225069038	20140505T000000	2280000.0	7	8.0	

	sqft_living	sqft_lot	floors	waterfront	view	…	grade	\
7252	12050	27600	2.5	0	3	…	13	
12777	13540	307752	3.0	0	4	…	12	

	sqft_above	sqft_basement	yr_built	yr_renovated	zipcode	lat	\
7252	8570	3480	1910	1987	98102	47.6298	
12777	9410	4130	1999	0	98053	47.6675	

	long	sqft_living15	sqft_lot15
7252	-122.323	3940	8800
12777	-121.986	4850	217800

[2 rows x 21 columns]

[148]:
```
df[df['bathrooms'] == 0]
#id 875 abbérant
```

[148]:

	id	date	price	bedrooms	bathrooms	\
875	6306400140	20140612T000000	1095000.0	0	0.0	
1149	3421079032	20150217T000000	75000.0	1	0.0	
3119	3918400017	20150205T000000	380000.0	0	0.0	
5832	5702500050	20141104T000000	280000.0	1	0.0	
6994	2954400190	20140624T000000	1295650.0	0	0.0	
9773	3374500520	20150429T000000	355000.0	0	0.0	
9854	7849202190	20141223T000000	235000.0	0	0.0	
10481	203100435	20140918T000000	484000.0	1	0.0	
14423	9543000205	20150413T000000	139950.0	0	0.0	
19452	3980300371	20140926T000000	142000.0	0	0.0	

	sqft_living	sqft_lot	floors	waterfront	view	…	grade	\
875	3064	4764	3.5	0	2	…	7	
1149	670	43377	1.0	0	0	…	3	
3119	1470	979	3.0	0	2	…	8	
5832	600	24501	1.0	0	0	…	3	
6994	4810	28008	2.0	0	0	…	12	
9773	2460	8049	2.0	0	0	…	8	
9854	1470	4800	2.0	0	0	…	7	
10481	690	23244	1.0	0	0	…	7	
14423	844	4269	1.0	0	0	…	7	
19452	290	20875	1.0	0	0	…	1	

```
       sqft_above  sqft_basement  yr_built  yr_renovated  zipcode      lat  \
875          3064              0      1990             0    98102  47.6362
1149          670              0      1966             0    98022  47.2638
3119         1470              0      2006             0    98133  47.7145
5832          600              0      1950             0    98045  47.5316
6994         4810              0      1990             0    98053  47.6642
9773         2460              0      1990             0    98031  47.4095
9854         1470              0      1996             0    98065  47.5265
10481         690              0      1948             0    98053  47.6429
14423         844              0      1913             0    98001  47.2781
19452         290              0      1963             0    98024  47.5308

          long  sqft_living15  sqft_lot15
875   -122.322           2360        4000
1149  -121.906           1160       42882
3119  -122.356           1470        1399
5832  -121.749            990       22549
6994  -122.069           4740       35061
9773  -122.168           2520        8050
9854  -121.828           1060        7200
10481 -121.955           1690       19290
14423 -122.250           1380        9600
19452 -121.888           1620       22850

[10 rows x 21 columns]
```

On remarque ici que le nombre de bathrooms est un décimal et pas un int parce que on considère plusieurs types de Bathrooms. Source : https://www.kaggle.com/datasets/harlfoxem/housesalesprediction/discussion/24804?resource=download On a des “full-bathrooms” des “semi” etc…

0.3.4 sqft living info

Représente la superficie intérieure

[149]:
```
plt.figure(figsize=(20,10))
plt.hist(df['sqft_living'], bins=100, color='green')
plt.xlabel('sqft_living')
plt.ylabel('Number of houses')
plt.show()
```

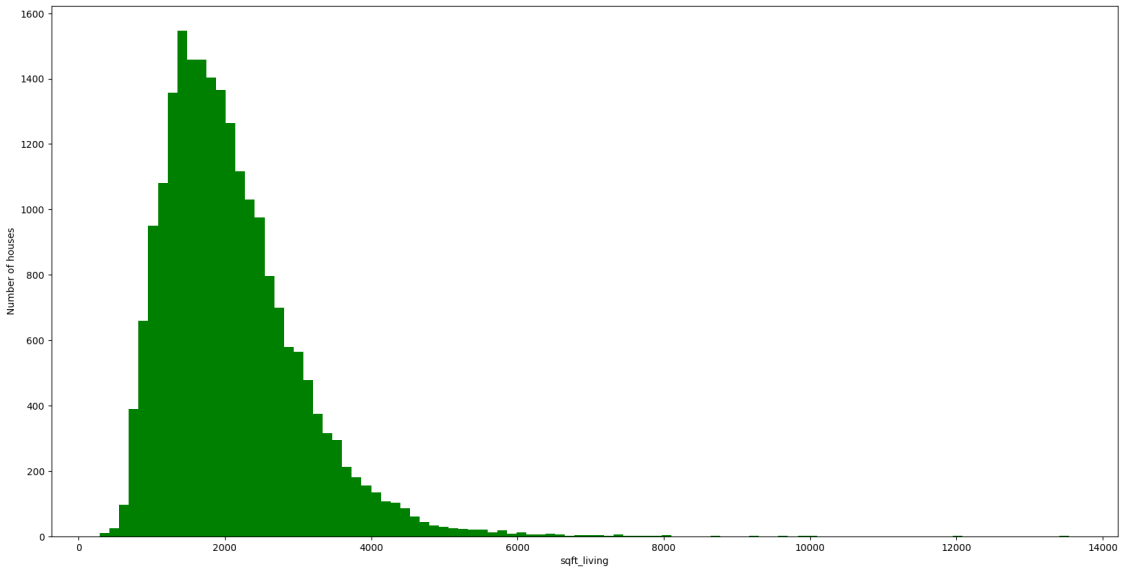

[150]:
```
#print info about sqft_living
df['sqft_living'].describe()
```

[150]:
```
count    21613.000000
mean      2079.899736
std        918.440897
min        290.000000
25%       1427.000000
50%       1910.000000
75%       2550.000000
max      13540.000000
Name: sqft_living, dtype: float64
```

Avoir une visualisation des tranches de 100 square foot

[151]:
```
# On arrondis au millier pour pouvoir compter la fréquence de chaque tranche␣
↪(de 100)
sqft_living_arrondis = [sq // 100 * 100 for sq in df['sqft_living']]
# Vérification de l'arrondis
# print(sqft_living_100[:100])
```

[152]:
```
pd_sqft_living_arrondis = pd.DataFrame(sqft_living_arrondis, dtype=int)
pd_sqft_living_arrondis.value_counts()
```

[152]:
```
1400    1158
1600    1135
1500    1123
1700    1078
```

```
1800     1066
         …
200         1
9200        1
8600        1
7600        1
13500       1
Length: 83, dtype: int64
```

[153]:
```
plt.figure(figsize=(20,10))
plt.hist(sqft_living_arrondis, bins=100, color='green')
plt.xlabel('sqft_living_arrondis')
plt.ylabel('Number of houses')
plt.show()
```

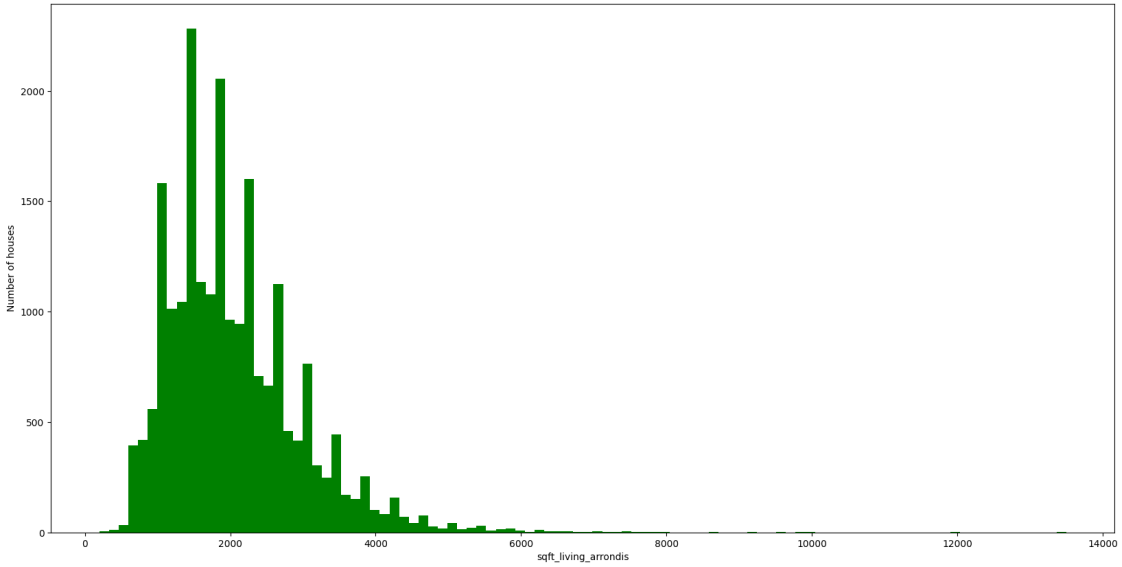

Vérification de la maison avec la valeur **max** pour *sqft_living*.

[154]:
```
df[df['sqft_living'] == 13540.000000]
```

[154]:
```
                id             date      price  bedrooms  bathrooms  \
12777  1225069038  20140505T000000  2280000.0         7        8.0

       sqft_living  sqft_lot  floors  waterfront  view  …  grade  \
12777        13540    307752     3.0           0     4  …     12

       sqft_above  sqft_basement  yr_built  yr_renovated  zipcode      lat  \
12777        9410           4130      1999             0    98053  47.6675
```

```
          long  sqft_living15  sqft_lot15
12777 -121.986           4850      217800

[1 rows x 21 columns]
```

Cette maison coûte 2 280 000 $ cela parait cohérent.

Vérification de la maison avec la valeur **min** pour *sqft_living*.

[155]:
```
df[df['sqft_living'] == 290]
```

[155]:
```
               id             date     price  bedrooms  bathrooms  \
19452  3980300371  20140926T000000  142000.0         0        0.0

       sqft_living  sqft_lot  floors  waterfront  view  …  grade  \
19452          290     20875     1.0           0     0  …      1

       sqft_above  sqft_basement  yr_built  yr_renovated  zipcode      lat  \
19452         290              0      1963             0    98024  47.5308

          long  sqft_living15  sqft_lot15
19452 -121.888           1620       22850

[1 rows x 21 columns]
```

En regardant sur google maps, on observe un cabanon autour d'un lac. De plus le terrain est grand. Le prix paraît cohérent.

0.3.5 sqft lot info

[156]:
```
plt.figure(figsize=(20,10))
plt.hist(df['sqft_lot'], bins=100, color='green')
plt.xlabel('sqft_lot')
plt.ylabel('Number of houses')
plt.show()
```

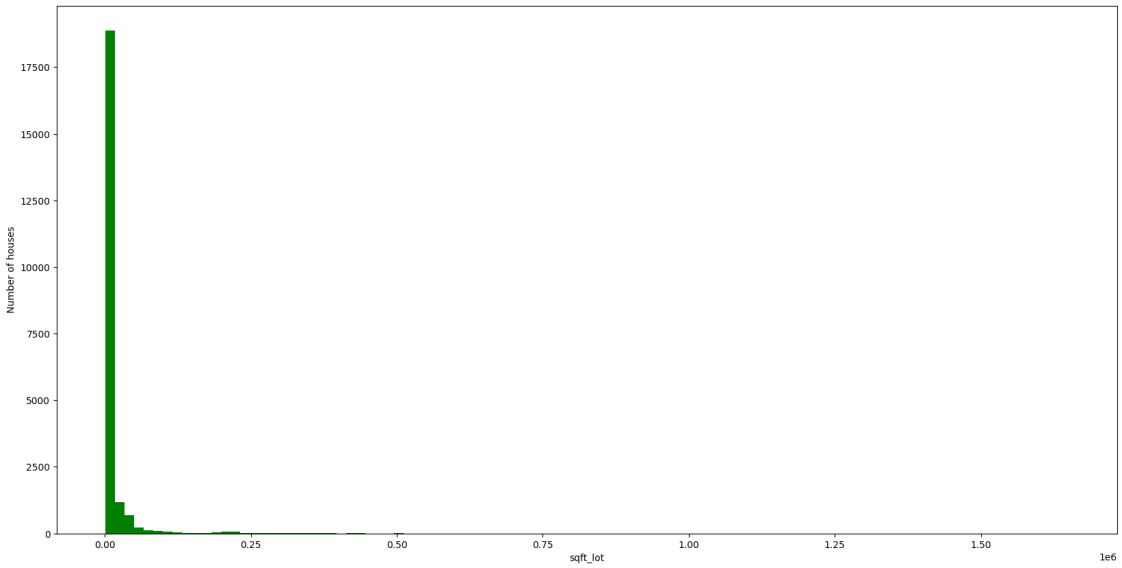

On constate que cette variable ne suit pas une loi normale. Nous allons donc par la suite prendre son logarithme.

0.3.6 Floors info

[157]:
```
plt.figure(figsize=(20,10))
plt.hist(df['floors'], bins=100, color='green')
plt.xlabel('floors')
plt.ylabel('Number of houses')
plt.show()
```

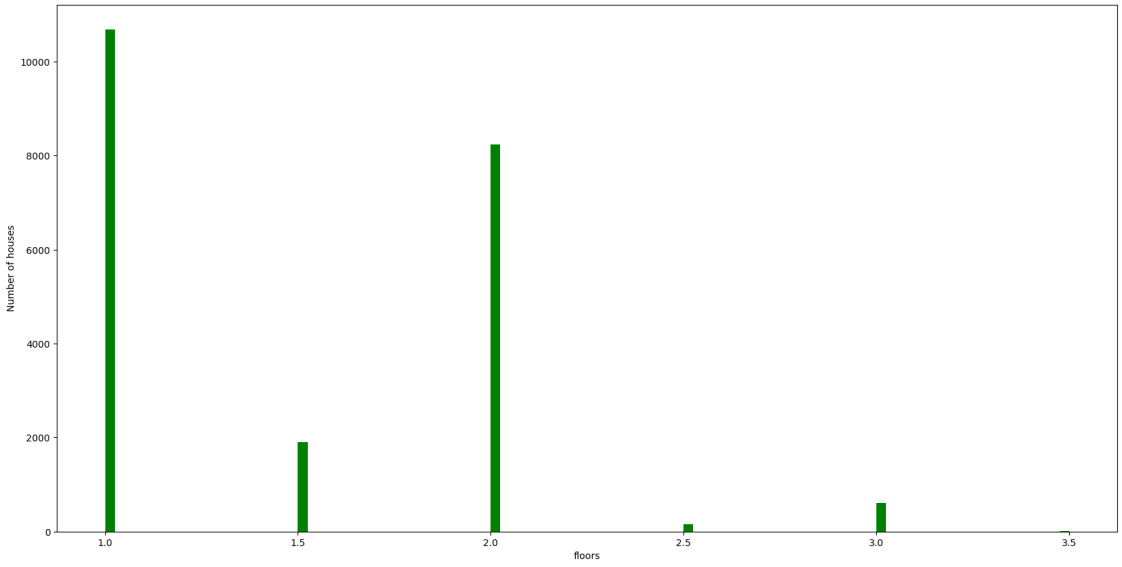

Nombre d'étages. Les demi-étages peuvent corresponde à des mezzanines.

0.3.7 Waterfront info

[158]:
```
plt.figure(figsize=(20,10))
plt.hist(df['waterfront'], bins=100, color='green')
plt.xlabel('waterfront')
plt.ylabel('Number of houses')
plt.show()
```

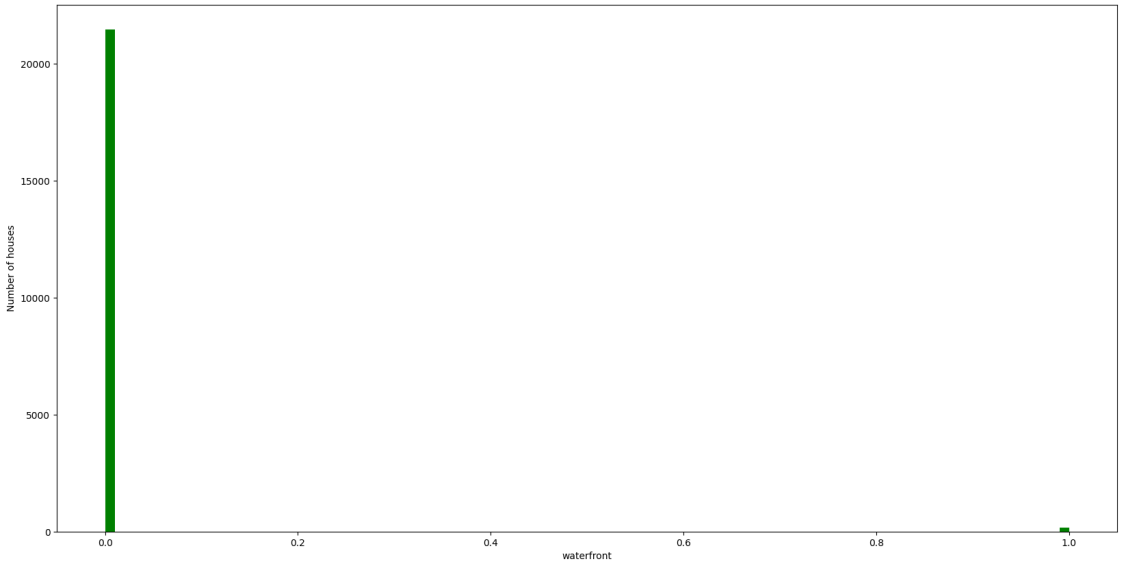

[159]:
```
df['waterfront'].value_counts()
```

[159]:
```
0    21450
1      163
Name: waterfront, dtype: int64
```

[160]:
```
df['waterfront'].describe()
```

[160]:
```
count    21613.000000
mean         0.007542
std          0.086517
min          0.000000
25%          0.000000
50%          0.000000
75%          0.000000
max          1.000000
Name: waterfront, dtype: float64
```

[161]:
```
#Show the price of the houses with a waterfront
df[df['waterfront'] == 1]['price'].describe()
#Price histogramme of the houses with a waterfront
plt.figure(figsize=(20,10))
plt.hist(df[df['waterfront'] == 1]['price'], bins=100, color='green')
plt.xlabel('Price')
plt.ylabel('Number of houses')
plt.show()
```

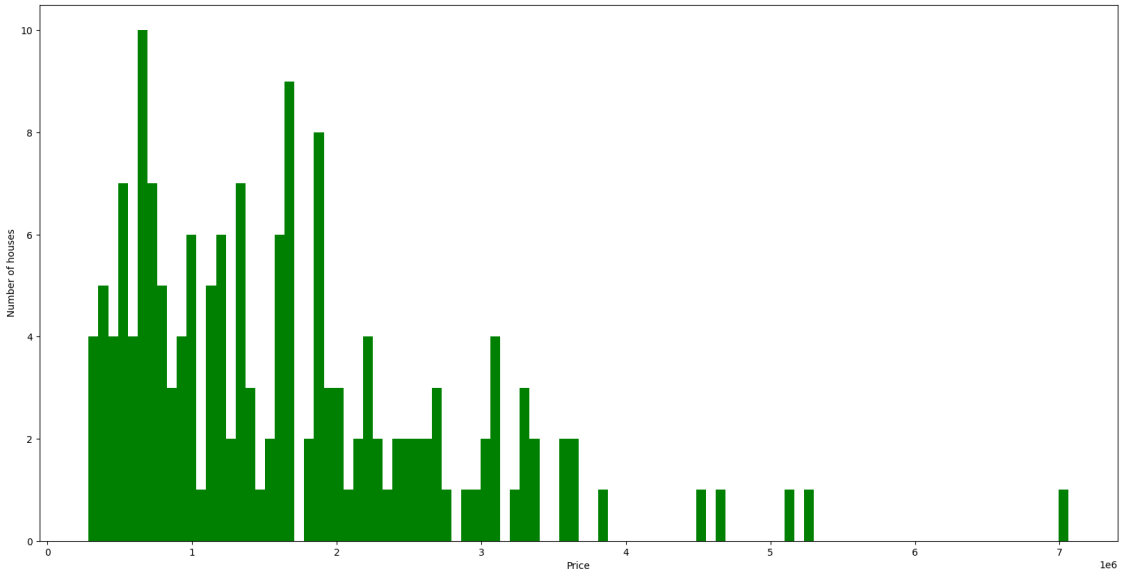

[162]:
```
#Show the price of the houses without a waterfront
df[df['waterfront'] == 0]['price'].describe()
#Price histogramme of the houses without a waterfront
plt.figure(figsize=(20,10))
plt.hist(df[df['waterfront'] == 0]['price'], bins=100, color='green')
plt.xlabel('Price')
plt.ylabel('Number of houses')
plt.show()
```

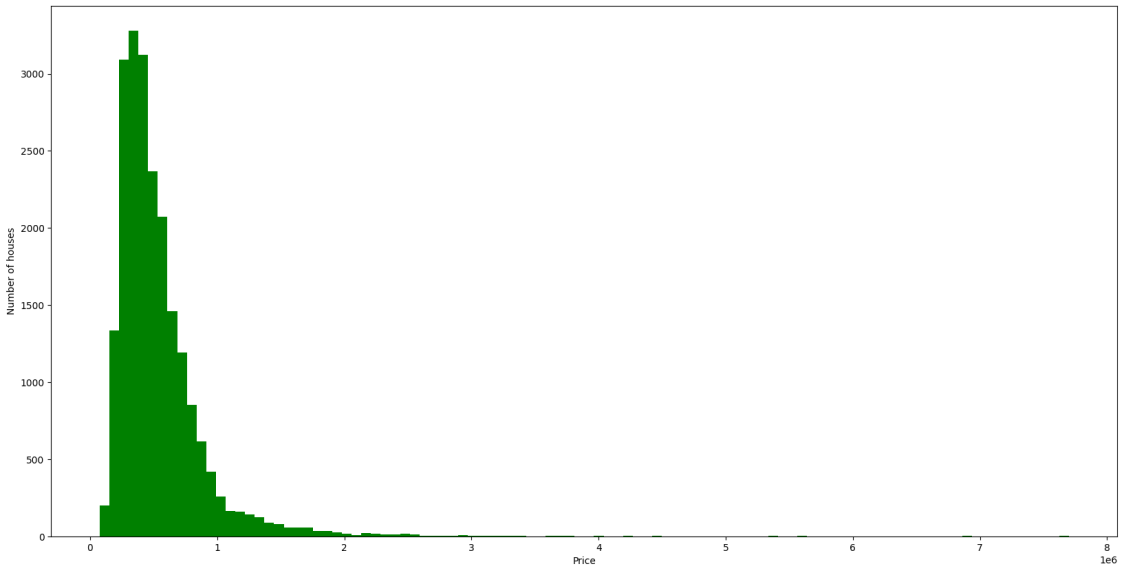

[163]:
```
#Select the house with waterfront
waterfronts=df[df['waterfront'] == 1]
#Get the row with the highest price in the waterfronts
waterfronts[waterfronts['price'] == waterfronts['price'].max()]
```

[163]:

	id	date	price	bedrooms	bathrooms	\
3914	9808700762	20140611T000000	7062500.0	5	4.5	

	sqft_living	sqft_lot	floors	waterfront	view	…	grade	sqft_above	\
3914	10040	37325	2.0	1	2	…	11	7680	

	sqft_basement	yr_built	yr_renovated	zipcode	lat	long	\
3914	2360	1940	2001	98004	47.65	-122.214	

	sqft_living15	sqft_lot15
3914	3930	25449

[1 rows x 21 columns]

0 ou 1 en fonction de si la maison est en face de l'eau ou non.

0.3.8 View info

[164]:
```
plt.figure(figsize=(20,10))
plt.hist(df['view'], bins=100, color='green')
plt.xlabel('view')
plt.ylabel('Number of houses')
plt.show()
```

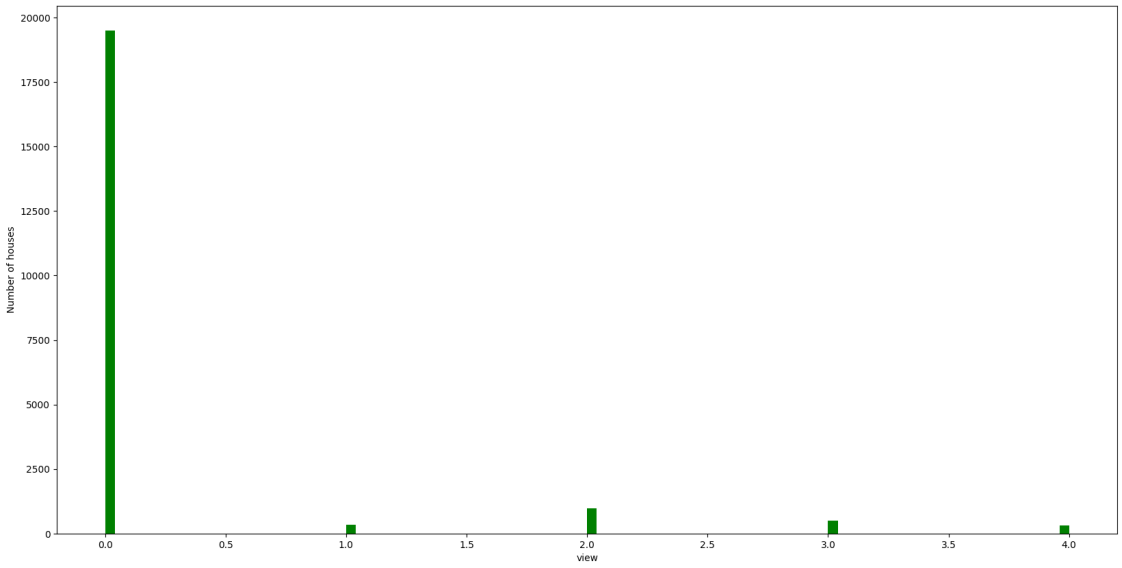

[165]:
```
df['view'].describe()
```

[165]:
```
count    21613.000000
mean         0.234303
std          0.766318
min          0.000000
25%          0.000000
50%          0.000000
75%          0.000000
max          4.000000
Name: view, dtype: float64
```

[166]:
```
df['view'].value_counts()
```

[166]:
```
0    19489
2      963
3      510
1      332
4      319
Name: view, dtype: int64
```

[167]:
```
#Show the price of the houses with a view
df[df['view'] == 1]['price'].describe()
#Price histogramme of the houses with a view
plt.figure(figsize=(20,10))
plt.hist(df[df['view'] == 1]['price'], bins=100, color='green')
plt.xlabel('Price')
```

[167]: Text(0.5, 0, 'Price')

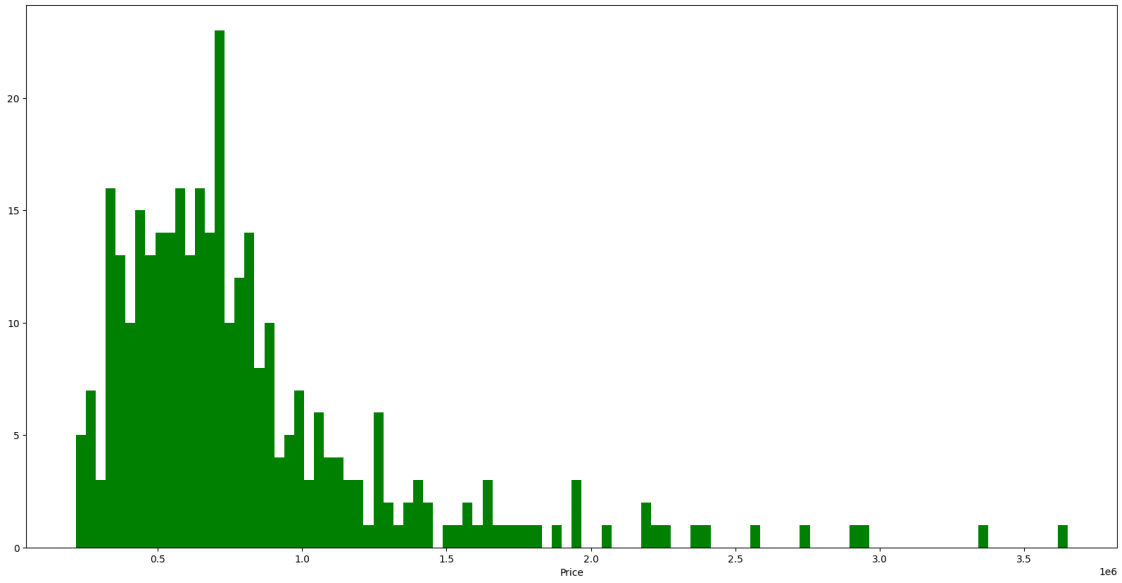

[168]:
```
#Choose the row with the highest price and view value of 4
views=df[(df['view'] == 4)]
views[views['price'] == views['price'].max()]
```

[168]:

	id	date	price	bedrooms	bathrooms	…	grade	sqft_above	sqft_basement	yr_built	yr_renovated	zipcode	lat	long	sqft_living15	sqft_lot15
9254	9208900037	20140919T000000	6885000.0	6	7.75	…	13	8860	1030	2001	0	98039	47.6305	-122.24	4540	42730

[1 rows x 21 columns]

Nombre de vue(s) de la maison (vue sur quelque chose).

0.3.9 Condition info

[169]:
```
plt.figure(figsize=(20,10))
plt.hist(df['condition'], bins=100, color='green')
plt.xlabel('condition')
plt.ylabel('Number of houses')
```

```
plt.show()
```

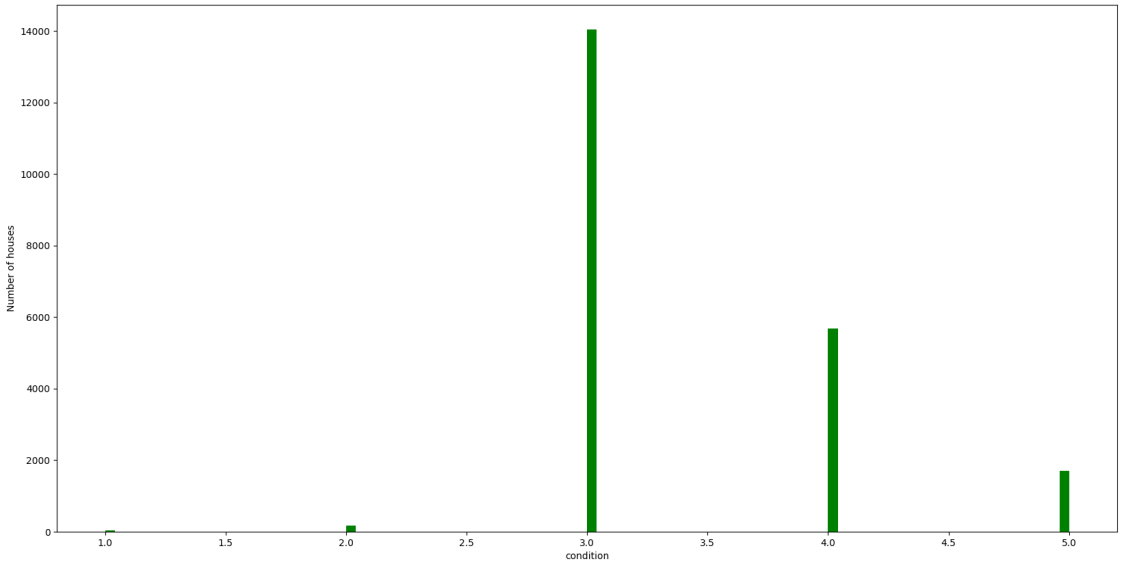

Les notes varient de 1 à 5. Indique la condition de la propriété (1 = mauvaise, 5 = excellente).

0.3.10 Grade info

[170]:
```
plt.figure(figsize=(20,10))
plt.hist(df['grade'], bins=100, color='green')
plt.xlabel('grade')
plt.ylabel('Number of houses')
plt.show()
```

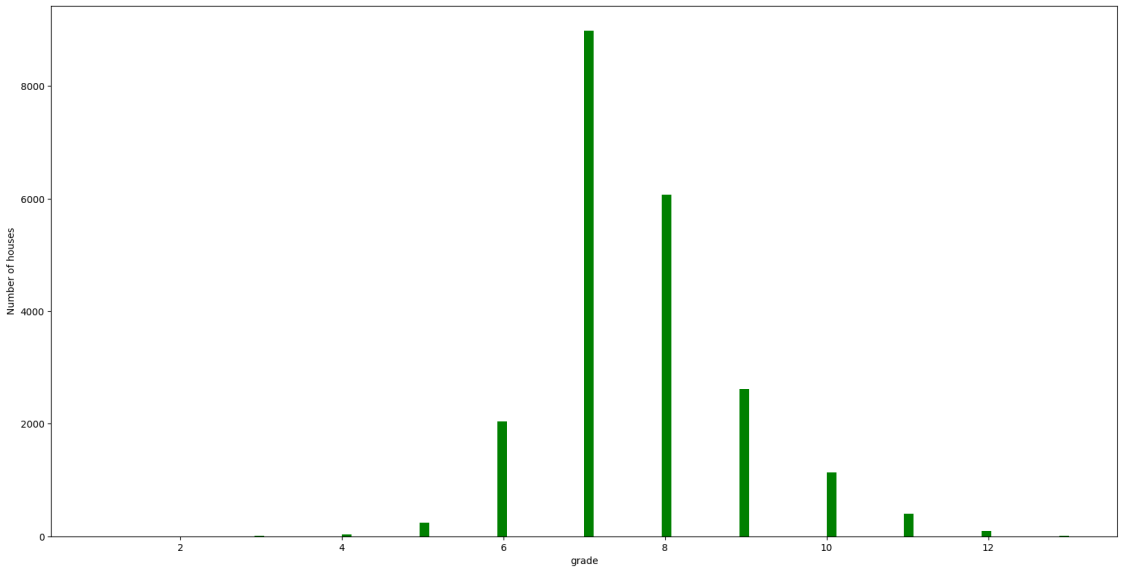

[171]:
```
df['grade'].describe()
```

[171]:
```
count    21613.000000
mean         7.656873
std          1.175459
min          1.000000
25%          7.000000
50%          7.000000
75%          8.000000
max         13.000000
Name: grade, dtype: float64
```

Les notes varient de 1 à 13. Elles représentent la qualité de la construction de la maison. On peut voir que la majorité des maisons ont une note comprise entre 7 et 8.

0.3.11 Sqft above info

[172]:
```
plt.figure(figsize=(20,10))
plt.hist(df['sqft_above'], bins=100, color='green')
plt.xlabel('sqft_above')
plt.ylabel('Number of houses')
plt.show()
```

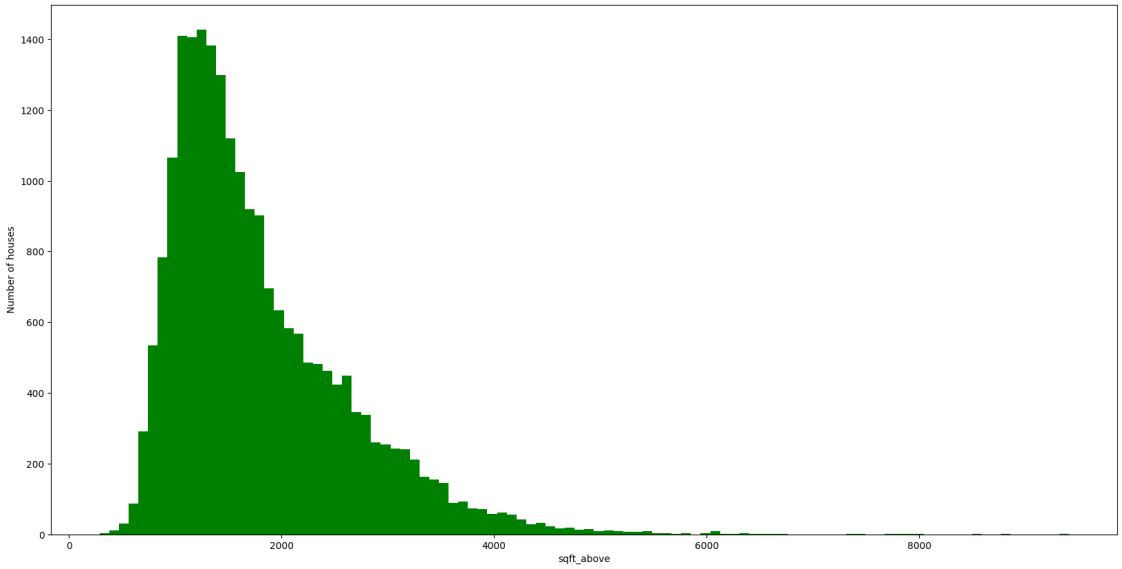

Surface vivable au dessus du niveau du sol (i.e. exclu le sous-sol). La distribution est normale.

0.3.12 Sqft basement info

[173]:
```
plt.figure(figsize=(20,10))
plt.hist(df['sqft_basement'], bins=100, color='green')
plt.xlabel('sqft_basement')
plt.ylabel('Number of houses')
plt.show()
```

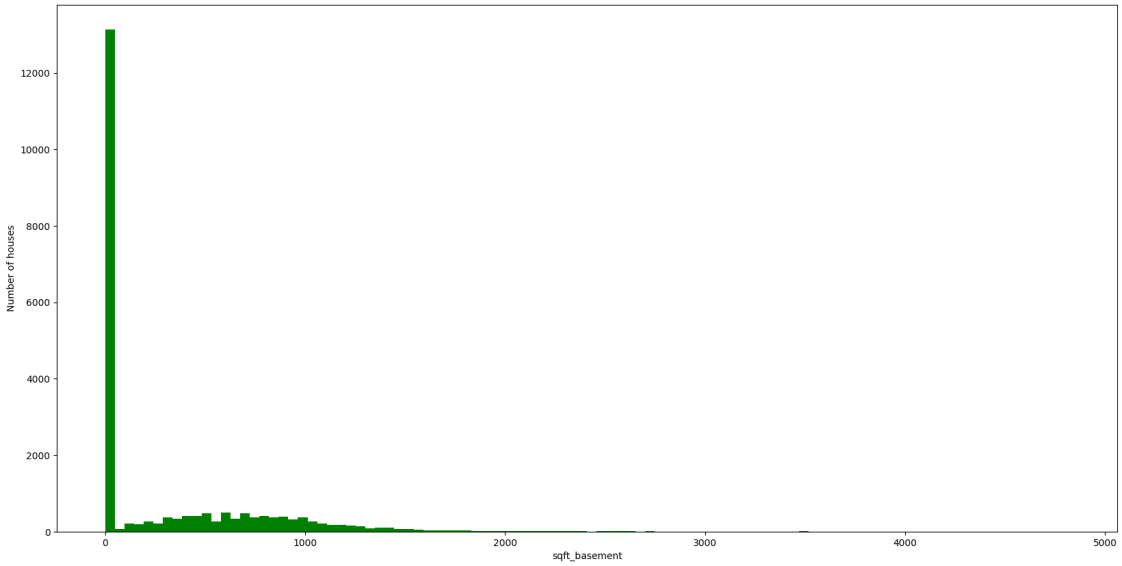

Surface du sous-sol. La distribution est normale si on ne considère pas les maisons sans sous-sol.

0.3.13 Year built info

[174]:
```
plt.figure(figsize=(20,10))
plt.hist(df['yr_built'], bins=100, color='green')
plt.xlabel('Year built')
plt.ylabel('Number of houses')
plt.show()
```

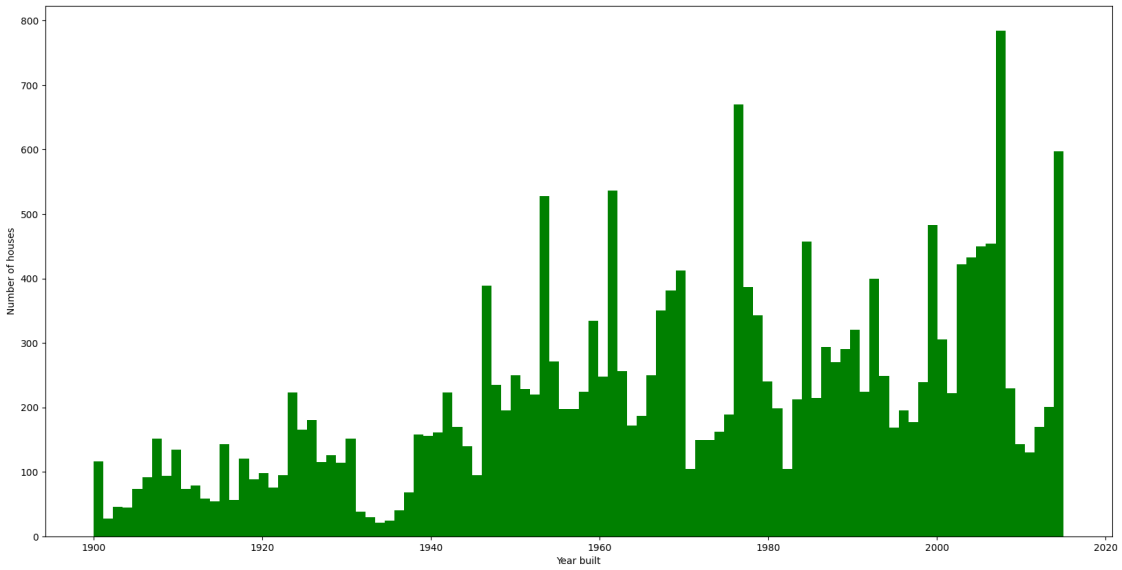

[175]:
```
df['yr_built'].describe()
```

[175]:
```
count    21613.000000
mean      1971.005136
std         29.373411
min       1900.000000
25%       1951.000000
50%       1975.000000
75%       1997.000000
max       2015.000000
Name: yr_built, dtype: float64
```

Les maisons sont toutes construites entre 1900 et 2015. La moitié des maisons ont été construites après 1975.

0.3.14 Year renovated info

[225]:
```
renovated_houses = df[df['yr_renovated'] != 0]
plt.figure(figsize=(20,10))
plt.hist(renovated_houses["yr_renovated"], bins=100, color='green')
plt.xlabel('Year renovated')
plt.ylabel('Number of houses')
plt.show()
```

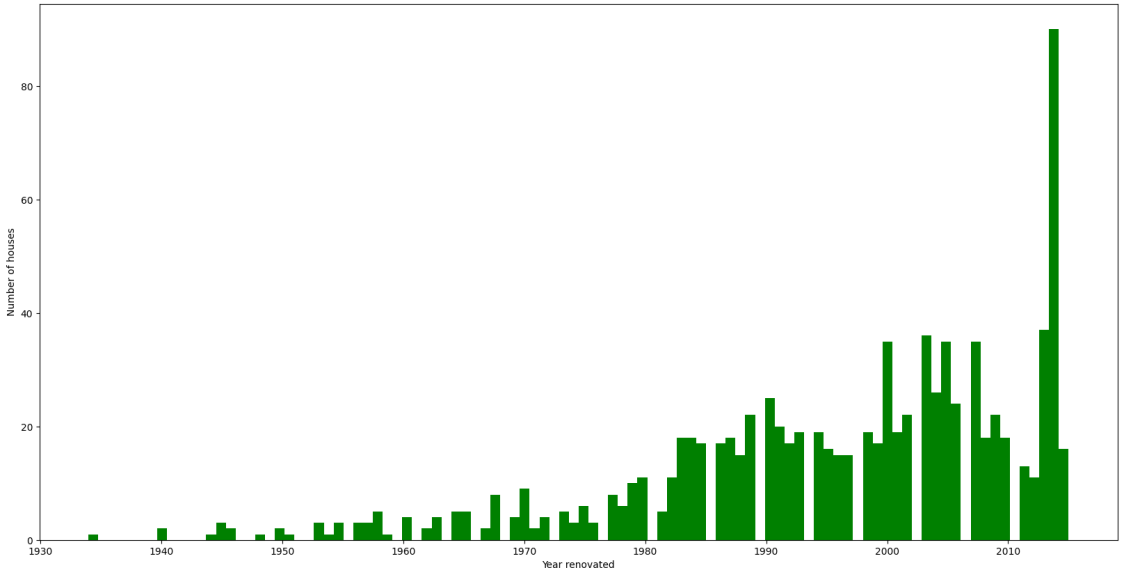

[177]:
```
# Uniquement les maisons qui ont été rénovées
renovated_houses['yr_renovated'].describe()
```

[177]:
```
count     914.000000
mean     1995.827133
std        15.517107
min      1934.000000
25%      1987.000000
50%      2000.000000
75%      2007.000000
max      2015.000000
Name: yr_renovated, dtype: float64
```

[178]:
```
# Toutes les maisons
df['yr_renovated'].describe()
```

[178]:
```
count    21613.000000
mean        84.402258
std        401.679240
min          0.000000
25%          0.000000
50%          0.000000
75%          0.000000
max       2015.000000
Name: yr_renovated, dtype: float64
```

Cette variable nous permet de savoir quand est-ce qu'une maison a été rennovée. Les maisons qui n'ont pas été rennovées ont une valeur de 0. On peut voir que la majorité des maisons n'ont pas

été rennovées. Pour celles qui ont été rennovées, elles l'ont été entre 1934 et 2015.

0.3.15 Zipcode info

[179]:
```
plt.figure(figsize=(20,10))
plt.hist(df['zipcode'], bins=100, color='green')
plt.xlabel('Zipcode')
plt.ylabel('Number of houses')
plt.show()
```

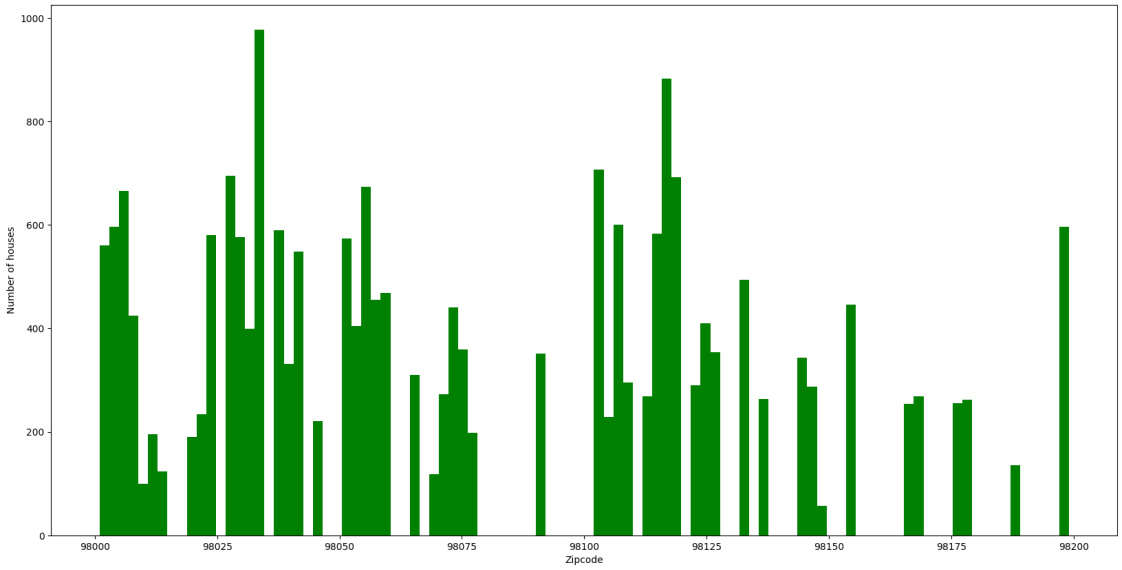

Rien de particulier à remarquer.

0.3.16 Latitude et longitude info

[180]:
```
plt.figure(figsize=(20,10))
plt.hist(df['lat'], bins=100, color='green')
plt.xlabel('Lat')
plt.ylabel('Number of houses')
plt.show()
```

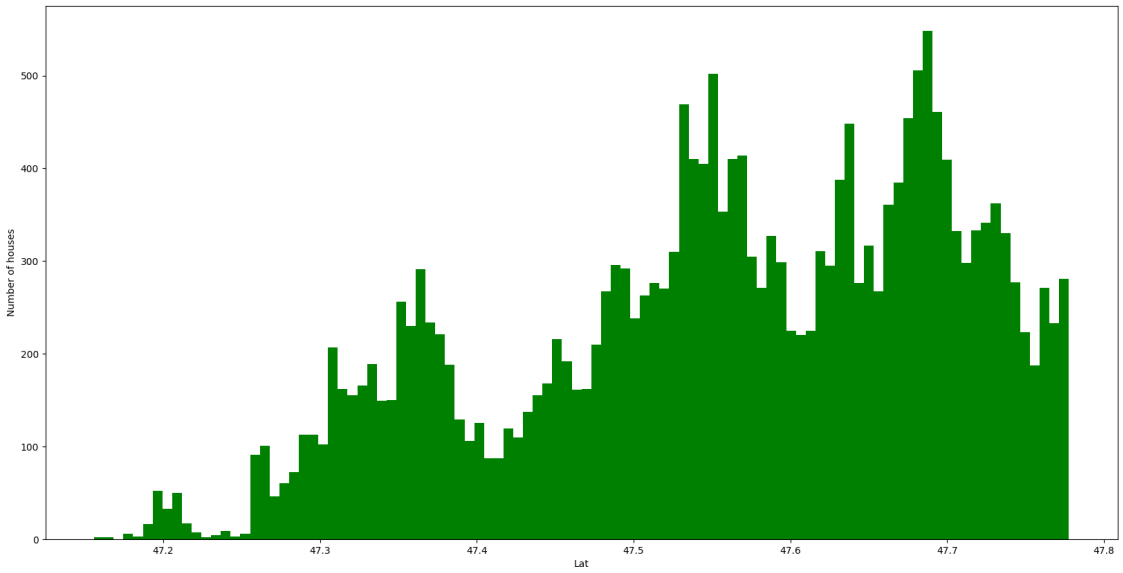

[181]:
```
plt.figure(figsize=(20,10))
plt.hist(df['long'], bins=100, color='green')
plt.xlabel('Long')
plt.ylabel('Number of houses')
plt.show()
```

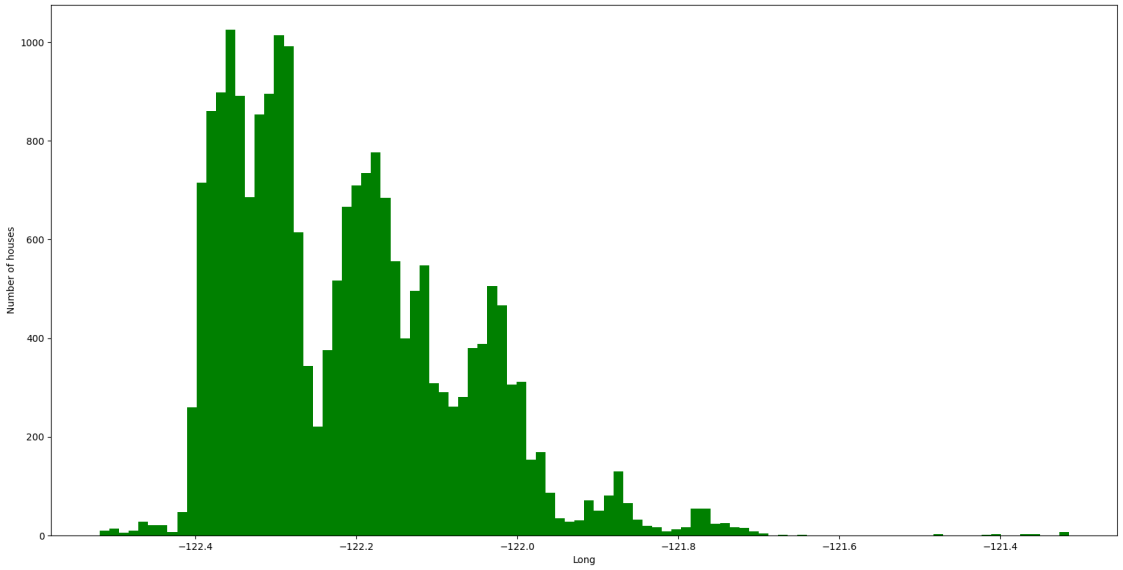

Rien de particulier à remarquer

0.3.17 Sqft living15 et Sqft lot15 info

[182]:
```
plt.figure(figsize=(20,10))
plt.hist(df['sqft_living15'], bins=100, color='green')
plt.xlabel('sqft_living15')
plt.ylabel('Number of houses')
plt.show()
```

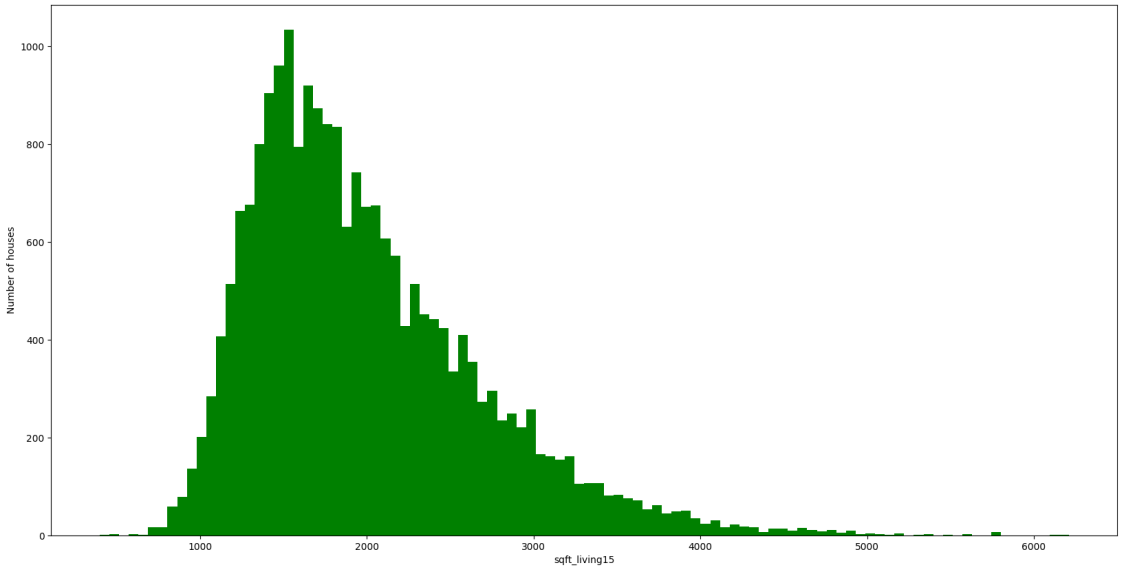

[183]:
```
plt.figure(figsize=(20,10))
plt.hist(df['sqft_lot15'], bins=100, color='green')
plt.xlabel('sqft_lot15')
plt.ylabel('Number of houses')
plt.show()
```

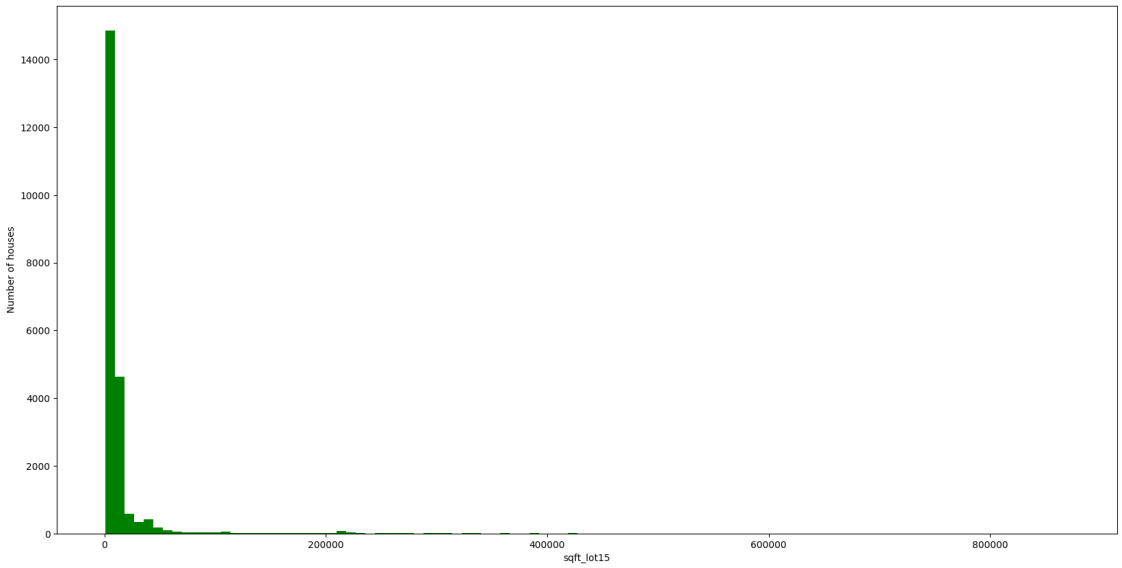

La distribution de sqft_lot15 est exponentielle. On va donc prendre son logarithme. Celle de sqft_living15 est normale.

0.3.18 Taille de la maison et du terrain

SQDT Living 15 : Surface habitable moyenne des 15 voisins les plus proches. Maison qui sont 25% plus grande que la moyenne des 15 voisins les plus proches (3930 maisons) et donc avantagées :

[184]:
```
# sqft_living15 : average size of 15 closest houses
# Houses that are 25% bigger than their neighbours in average
# Those houses have a comparatible advantage on their nearest neighbours
df[df['sqft_living'] > 1.25*df['sqft_living15']]
```

[184]:

	id	date	price	bedrooms	bathrooms	\
1	6414100192	20141209T000000	538000.0	3	2.25	
3	2487200875	20141209T000000	604000.0	4	3.00	
10	1736800520	20150403T000000	662500.0	3	2.50	
14	1175000570	20150312T000000	530000.0	5	2.00	
15	9297300055	20150124T000000	650000.0	4	3.00	
…	…	…	…	…	…	
21593	8672200110	20150317T000000	1088000.0	5	3.75	
21597	191100405	20150421T000000	1575000.0	4	3.25	
21600	249000205	20141015T000000	1537000.0	5	3.75	
21606	7936000429	20150326T000000	1007500.0	4	3.50	
21609	6600060120	20150223T000000	400000.0	4	2.50	

	sqft_living	sqft_lot	floors	waterfront	view	…	grade	\
1	2570	7242	2.0	0	0	…	7	
3	1960	5000	1.0	0	0	…	7	

```
10            3560      9796     1.0           0     0  …      8
14            1810      4850     1.5           0     0  …      7
15            2950      5000     2.0           0     3  …      9
…              …         …        …          …    …  …    …
21593         4170      8142     2.0           0     2  …     10
21597         3410     10125     2.0           0     0  …     10
21600         4470      8088     2.0           0     0  …     11
21606         3510      7200     2.0           0     0  …      9
21609         2310      5813     2.0           0     0  …      8

       sqft_above  sqft_basement  yr_built  yr_renovated  zipcode      lat  \
1            2170            400      1951          1991    98125  47.7210
3            1050            910      1965             0    98136  47.5208
10           1860           1700      1965             0    98007  47.6007
14           1810              0      1900             0    98107  47.6700
15           1980            970      1979             0    98126  47.5714
…             …              …         …             …       …       …
21593        4170              0      2006             0    98056  47.5354
21597        3410              0      2007             0    98040  47.5653
21600        4470              0      2008             0    98004  47.6321
21606        2600            910      2009             0    98136  47.5537
21609        2310              0      2014             0    98146  47.5107

          long  sqft_living15  sqft_lot15
1     -122.319           1690        7639
3     -122.393           1360        5000
10    -122.145           2210        8925
14    -122.394           1360        4850
15    -122.375           2140        4000
…        …             …          …
21593 -122.181           3030        7980
21597 -122.223           2290       10125
21600 -122.200           2780        8964
21606 -122.398           2050        6200
21609 -122.362           1830        7200

[3930 rows x 21 columns]
```

0.4 Nettoyage des données

[185]:
```
# Formatage date
df['date'] = df['date'].astype('datetime64[ns]')
df['date'] = pd.to_datetime(df['date'])
df['date']=df['date'].map(dt.datetime.toordinal)
```

On remarque certaines maisons sont plus grandes que les terrains sur lesquel elles sont construites :

[186]:
```
# Houses that are somehow bigger than the lot they are in..
df[df['sqft_living']/df['floors'] > df['sqft_lot']]
```

[186]:

	id	date	price	bedrooms	bathrooms	sqft_living	\
1549	8816400885	735514	450000.0	4	1.75	1640	
3452	2559950110	735710	1234570.0	2	2.50	2470	
5800	2770604103	735445	450000.0	3	2.50	1530	
13253	2877104196	735573	760000.0	3	2.00	1780	
13278	3277800845	735425	370000.0	3	1.00	1170	
15743	9828702895	735528	700000.0	4	1.75	2420	
16931	5016002275	735386	610000.0	5	2.50	3990	
17434	2062600020	735422	530000.0	2	2.50	1785	

	sqft_lot	floors	waterfront	view	…	grade	sqft_above	\
1549	1480	1.0	0	0	…	7	820	
3452	609	3.0	0	0	…	11	1910	
5800	762	2.0	0	0	…	8	1050	
13253	1750	1.0	0	2	…	8	1400	
13278	1105	1.0	0	0	…	7	1170	
15743	520	1.5	0	0	…	7	2420	
16931	3839	1.0	0	0	…	8	1990	
17434	779	2.0	0	0	…	7	1595	

	sqft_basement	yr_built	yr_renovated	zipcode	lat	long	\
1549	820	1912	0	98105	47.6684	-122.314	
3452	560	2011	0	98112	47.6182	-122.312	
5800	480	2007	0	98119	47.6420	-122.374	
13253	380	1927	2014	98103	47.6797	-122.357	
13278	0	1965	0	98126	47.5448	-122.375	
15743	0	1900	0	98112	47.6209	-122.302	
16931	2000	1962	0	98112	47.6236	-122.299	
17434	190	1975	0	98004	47.5959	-122.198	

	sqft_living15	sqft_lot15
1549	1420	2342
3452	2440	1229
5800	1610	1482
13253	1780	3750
13278	1380	1399
15743	1200	1170
16931	2090	5000
17434	1780	794

[8 rows x 21 columns]

[187]:
```
# Maison qui sont plus grandes que le terrain sur lequel elles sont construites
df = df.drop(df[df['sqft_living']/df['floors'] > df['sqft_lot']].index)
```

[188]:
```
# Maison qui a 33 chambres pour une superficie d'environ 162m² et 1 seul étage
df = df.drop(df[df['bedrooms'] == 33].index)
df = df.drop(df[df['bedrooms'] == 0].index)
df = df.drop(df[df['bathrooms'] == 0].index)
```

[189]:
```
# Passage de la variable sqft_lot à son logarithme
df["sqft_lot"] = np.log(df['sqft_lot'])
```

[190]:
```
# Passage de la variable sqft_lot15 à son logarithme
df["sqft_lot15"] = np.log(df['sqft_lot15'])
```

On constate qu'en prenant le logarithme de sqft_lot, l'ensemble des modèles sont plus performants.

0.5 Modèles prédictifs

0.5.1 Modèle simple de régression linéaire

[191]:
```
#etude de la correlation
matrice_corr = df.corr().round(1)
sns.heatmap(data=matrice_corr, annot=True)
```

[191]: <Axes: >

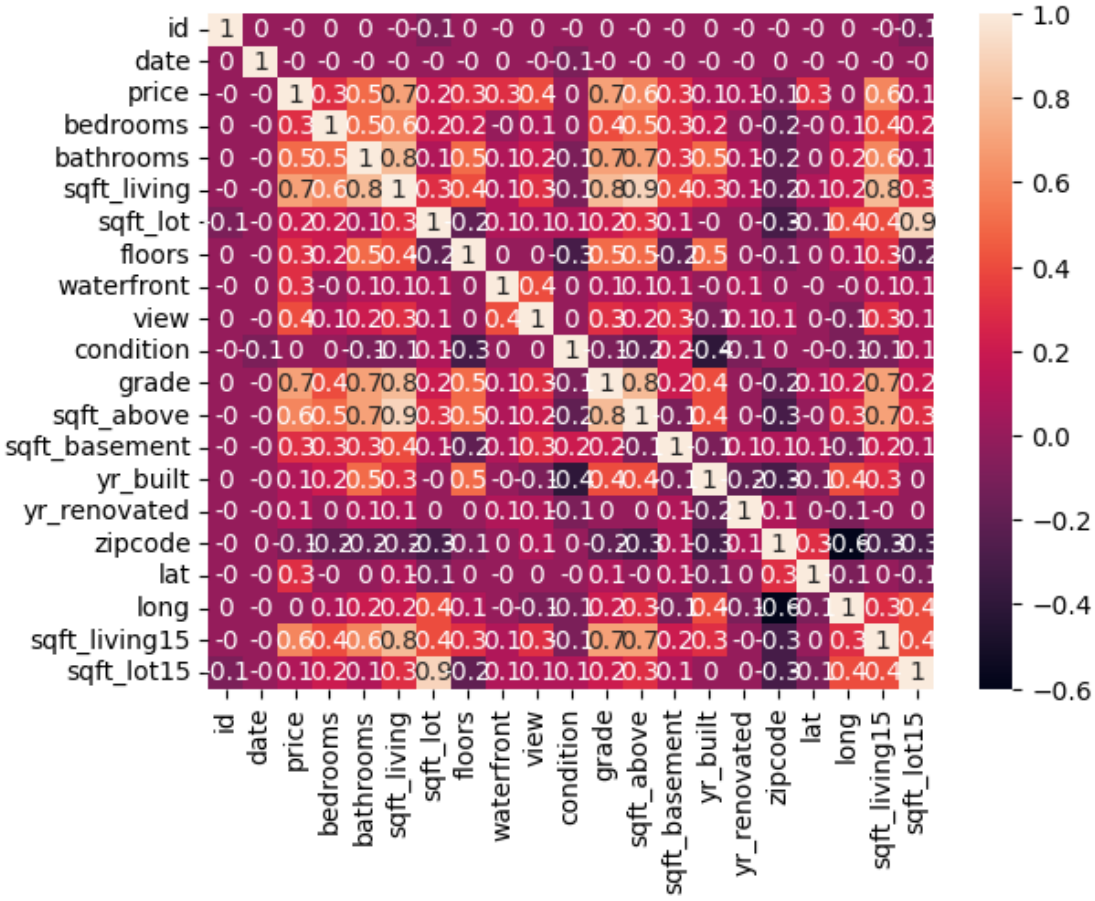

Grâce à cette matrice de corrélation, on regarde la corrélation des différentes variables avec le prix. Il faut choisir les variables à retenir pour notre modèle en retenant celles qui sont le plus fort coefficient de corrélation. On constate que les coefficients vont de 0 à 0.7 (en valeurs absolues). On peut choisir de retenir les qui ont un coefficient supérieur ou égal à 0.4 en valeur absolue. On retient donc bathrooms, sqft_living, view, grade, sqfr_above et sqft_living15.

Mise en place du modèle

[192]:
```
#on utilise seulement les variables qui ont une correlation avec le prix
X=pd.DataFrame(np.
  ↪c_[df['bathrooms'],df['sqft_living'],df['view'],df['grade'],df['sqft_above'],df['sqft_livin
  ↪columns =␣
  ↪['bathrooms','sqft_living','view','grade','sqft_above','sqft_living15'])
Y = df['price']

#base d'apprentissage et base de test

X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.2,␣
  ↪random_state=5)
```

```
print(X_train.shape)
print(X_test.shape)
print(Y_train.shape)
print(Y_test.shape)
```

```
(17270, 6)
(4318, 6)
(17270,)
(4318,)
```

Entrainement du modèle

[193]:
```
#entrainement du modèle

lmodellineaire = LinearRegression()
lmodellineaire.fit(X_train, Y_train)
```

[193]:
```
LinearRegression()
```

Evaluation du modèle

[194]:
```
# Evaluation du training set

y_train_predict = lmodellineaire.predict(X_train)
rmse = (np.sqrt(mean_squared_error(Y_train, y_train_predict)))

print("La performance du modèle sur la base d'apprentissage")
print('--------------------------------------')
print("L'erreur quadratique moyenne est {}".format(rmse))
print('\n')

# model evaluation for testing set
y_test_predict = lmodellineaire.predict(X_test)
rmse = (np.sqrt(mean_squared_error(Y_test, y_test_predict)))

print('La performance du modèle sur la base de test')
print('--------------------------------------')
print("L'erreur quadratique moyenne est {}".format(rmse))
```

```
La performance du modèle sur la base d'apprentissage
--------------------------------------
L'erreur quadratique moyenne est 239994.52326066705


La performance du modèle sur la base de test
--------------------------------------
L'erreur quadratique moyenne est 235432.39753876044
```

Le modèle n'est pas trop mauvais. L'erreur quadratique moyenne est d'environ

$240000, cequiestdel'ordredel'cart - typeduprixdesmaisons(370000)$.

0.5.2 Modèle simple de régression linéaire avec toutes les variables

Mise en place du modèle

[195]:
```
# On exclue le l'id de la maison qui n'a aucune influence sur le prix
X = df.loc[:, ~df.columns.isin(['id','price'])]
Y = df['price']

#base d'apprentissage et base de test

X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.2,␣
 ↪random_state=5)
```

Entrainement du modèle

[196]:
```
#entrainement du modèle

lmodellineaire = LinearRegression()
lmodellineaire.fit(X_train, Y_train)
```

[196]:
```
LinearRegression()
```

Evaluation du modèle

[197]:
```
# Evaluation du training set

y_train_predict = lmodellineaire.predict(X_train)
rmse = (np.sqrt(mean_squared_error(Y_train, y_train_predict)))

print("La performance du modèle sur la base d'apprentissage")
print('--------------------------------------')
print("L'erreur quadratique moyenne est {}".format(rmse))
print('\n')

# model evaluation for testing set
y_test_predict = lmodellineaire.predict(X_test)
rmse = (np.sqrt(mean_squared_error(Y_test, y_test_predict)))

print('La performance du modèle sur la base de test')
print('--------------------------------------')
print("L'erreur quadratique moyenne est {}".format(rmse))
```

```
La performance du modèle sur la base d'apprentissage
--------------------------------------
L'erreur quadratique moyenne est 200279.08702527333



La performance du modèle sur la base de test
```

```
--------------------------------------
L'erreur quadratique moyenne est 197664.4612274257
```

L'erreur quadratique moyenne est ici plus faible (200 000$). Le modèle est meilleur. Il peut cependant être intéressant de pousser l'analyse en utilisant un modèle avec régularisation.

0.5.3 Ridge Regression

Mise en place du modèle

[198]:
```
X = df.loc[:, ~df.columns.isin(['id','price'])]
Y = df['price']

X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.2,␣
 ↪random_state=5)
```

Recherche du meilleur hyperparameter alpha

[199]:
```
ridge=Ridge()
parameters = {'alpha': (np.logspace(-8, 8, 100))}
#parameters={'alpha':[1e-15,1e-10,1e-8,1e-3,1e-2,1e-1,0.5,1,1.
 ↪5,2,5,10,20,30,35,40,45,50,55,100]}
ridge_regressor=GridSearchCV(ridge,parameters,scoring='neg_mean_squared_error',cv=10)
ridge_regressor.fit(X_train,Y_train)

alpha_ridge = ridge_regressor.best_params_["alpha"]
print('alpha : {}'.format(alpha))
```

```
alpha : 1e-08
```

Entrainement du modèle

[200]:
```
ridgereg = make_pipeline(StandardScaler(), Ridge(alpha=alpha_ridge))
ridgereg.fit(X_train,Y_train)
```

[200]:
```
Pipeline(steps=[('standardscaler', StandardScaler()),
                ('ridge', Ridge(alpha=0.39442060594376643))])
```

Evaluation du modèle

[201]:
```
# Evaluation du training set

Y_train_pred = ridgereg.predict(X_train)
Y_test_pred = ridgereg.predict(X_test)
#print('MSE train: %.3f, test: %.3f' % (mean_squared_error(Y_train,␣
 ↪Y_train_pred),mean_squared_error(Y_test, Y_test_pred)))

Y_train_predict = ridgereg.predict(X_train)
rmse = (np.sqrt(mean_squared_error(Y_train, Y_train_predict)))
```

```
print("La performance du modèle sur la base d'apprentissage")
print('--------------------------------------')
print("L'erreur quadratique moyenne est {}".format(rmse))
print('\n')

# model evaluation for testing set
Y_test_predict = ridgereg.predict(X_test)
rmse = (np.sqrt(mean_squared_error(Y_test, Y_test_predict)))

print('La performance du modèle sur la base de test')
print('--------------------------------------')
print("L'erreur quadratique moyenne est {}".format(rmse))
```

```
La performance du modèle sur la base d'apprentissage
--------------------------------------
L'erreur quadratique moyenne est 200279.08711811327


La performance du modèle sur la base de test
--------------------------------------
L'erreur quadratique moyenne est 197664.57293403274
```

Les performances de la Ridge Regression sont très similaires à celles de la régression linéaire simple. Nous allons donc explorer la régression Lasso.

0.5.4 Lasso

0.5.5 Mise en place du modèle

[202]:
```
X = df.loc[:, ~df.columns.isin(['id','price'])]
Y = df['price']

X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.2,␣
 ↪random_state=5)
```

Recherche du meilleur hyperparameter alpha

[203]:
```
# Attention : la recherche est longue (compter 10-15 minutes)
lasso=Lasso(normalize=True)
parameters = {'alpha': (np.logspace(-8, 8, 100))}
lasso_regressor=GridSearchCV(lasso,parameters,cv=3)
lasso_regressor.fit(X_train,Y_train)

lasso_alpha = lasso_regressor.best_params_["alpha"]

print(lasso_regressor.best_params_)
print(lasso_regressor.best_score_)
```

```
{'alpha': 1e-08}
0.7000250726816066
```

Entrainement du modèle

[204]:
```
lassoreg = Lasso(alpha = lasso_alpha, normalize = True)
lassoreg.fit(X_train, Y_train)
```

[204]:
```
Lasso(alpha=1e-08, normalize=True)
```

Evaluation du modèle

[205]:
```
print(lassoreg.score(X_test, Y_test))
```

```
0.7134943916492347
```

[206]:
```
# Evaluation du training set

Y_train_pred = lassoreg.predict(X_train)
Y_test_pred = lassoreg.predict(X_test)
#print('MSE train: %.3f, test: %.3f' % (mean_squared_error(Y_train,␣
 ↪Y_train_pred),mean_squared_error(Y_test, Y_test_pred)))

Y_train_predict = lassoreg.predict(X_train)
rmse = (np.sqrt(mean_squared_error(Y_train, Y_train_predict)))

print("La performance du modèle sur la base d'apprentissage")
print('--------------------------------------')
print("L'erreur quadratique moyenne est {}".format(rmse))
print('\n')

# model evaluation for testing set
Y_test_predict = lassoreg.predict(X_test)
rmse = (np.sqrt(mean_squared_error(Y_test, Y_test_predict)))

print('La performance du modèle sur la base de test')
print('--------------------------------------')
print("L'erreur quadratique moyenne est {}".format(rmse))
```

```
La performance du modèle sur la base d'apprentissage
--------------------------------------
L'erreur quadratique moyenne est 200279.08702527327


La performance du modèle sur la base de test
--------------------------------------
L'erreur quadratique moyenne est 197664.46122704283
```

De même, les résulats ne sont pas plus convaincants que ceux de la régression linéaire simple. Nous allons donc explorer la une régression non linéraire.

0.5.6 Random Forest

Mis en place du modèle

[207]:
```
X = df.loc[:, ~df.columns.isin(['id','price'])]
Y = df['price']

X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.2,␣
 ↪random_state=5)
```

Entrainement du modèle

[208]:
```
RFregressor = RandomForestRegressor(n_estimators = 100, random_state = 0)
# n_estimators = nombre d'arbres de décision, c'est-à-dire le nombre de modèles␣
 ↪que l'on va construire
RFregressor.fit(X_train, Y_train)
```

[208]:
```
RandomForestRegressor(random_state=0)
```

Evaluation du modèle

[209]:
```
# Evaluation du training set

Y_train_pred = RFregressor.predict(X_train)
Y_test_pred = RFregressor.predict(X_test)
#print('MSE train: %.3f, test: %.3f' % (mean_squared_error(Y_train,␣
 ↪Y_train_pred),mean_squared_error(Y_test, Y_test_pred)))

Y_train_predict = RFregressor.predict(X_train)
rmse = (np.sqrt(mean_squared_error(Y_train, Y_train_predict)))

print("La performance du modèle sur la base d'apprentissage")
print('--------------------------------------')
print("L'erreur quadratique moyenne est {}".format(rmse))
print('\n')

# model evaluation for testing set
Y_test_predict = RFregressor.predict(X_test)
rmse = (np.sqrt(mean_squared_error(Y_test, Y_test_predict)))

print('La performance du modèle sur la base de test')
print('--------------------------------------')
print("L'erreur quadratique moyenne est {}".format(rmse))
```

```
La performance du modèle sur la base d'apprentissage
--------------------------------------
L'erreur quadratique moyenne est 48683.80612073758


La performance du modèle sur la base de test
```

```
--------------------------------------
L'erreur quadratique moyenne est 134276.95802832497
```

On a un bien meilleur résultat avec le Random Forest. L'erreur quadratique moyenne est de 120 000$ sur le dataset de test. C'est donc un jeu de donnée qui est mieux prédit par un modèle non linéaire.

0.5.7 Kernel Ridge Regression

Mise en place du modèle

[217]:
```
X = df.loc[:, ~df.columns.isin(['id','price'])]
Y = df['price']
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.2,␣
 ↪random_state=42)

# On normalise les données
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
```

Entrainement du modèle

[218]:
```
from sklearn.kernel_ridge import KernelRidge

# Création en entrainement du modèle
KRregressor = KernelRidge(kernel='rbf', alpha=0.1, gamma=0.1)
KRregressor.fit(X_train, Y_train)
```

[218]:
```
KernelRidge(alpha=0.1, gamma=0.1, kernel='rbf')
```

Evaluation du modèle

[219]:
```
Y_train_pred = KRregressor.predict(X_train)
Y_test_pred = KRregressor.predict(X_test)

Y_train_predict = KRregressor.predict(X_train)
rmse = (np.sqrt(mean_squared_error(Y_train, Y_train_predict)))

print("La performance du modèle sur la base d'apprentissage")
print('--------------------------------------')
print("L'erreur quadratique moyenne est {}".format(rmse))
print('\n')

# model evaluation for testing set
Y_test_predict = KRregressor.predict(X_test)
rmse = (np.sqrt(mean_squared_error(Y_test, Y_test_predict)))

print('La performance du modèle sur la base de test')
print('--------------------------------------')
```

```
print("L'erreur quadratique moyenne est {}".format(rmse))
```

```
La performance du modèle sur la base d'apprentissage
--------------------------------------
L'erreur quadratique moyenne est 65552.21319669549


La performance du modèle sur la base de test
--------------------------------------
L'erreur quadratique moyenne est 149889.87533226088
```

Dans l'état actuel, le modèle est moins bon que la régression linéaire simple, ce qui est étonnant. Il faudrait donc modifier les hyperparamètres pour obtenir un meilleur résultat. Cependant, les hyperparamètres présentés sont ceux qui donnent les meilleurs résultats pour un temps de calcul raisonnable.

Le modèle semble meilleur que la régression linéaire simple. Cependant, il est plus long à calculer et semble moins bon qu'une Random Forest. Nous essayons d'utiliser l'approximation de Nyström pour accélérer le calcul.

0.5.8 Approximation de nyström for kernel ridge regression

Mise en place de l'approximation

[220]:
```
from sklearn.kernel_approximation import Nystroem

# Création d'un objet Nystroem avec n_components = 100
nystroem = Nystroem(kernel='rbf', n_components=100)

#On utilise la variable regressor de la partie précédente

X_train_nystroem = nystroem.fit_transform(X_train)

# Entraînement du modèle KernelRidge sur les données transformées par Nystroem
KRregressor_nys = KernelRidge(kernel='rbf', alpha=0.1, gamma=0.1)
KRregressor_nys.fit(X_train_nystroem, Y_train)

# Prédiction sur les données d'entraînement
Y_train_pred = KRregressor_nys.predict(X_train_nystroem)

# Calcul de l'erreur quadratique moyenne sur les données d'entraînement
rmse_train = np.sqrt(mean_squared_error(Y_train, Y_train_pred))

# Transformation des données de test avec la méthode de Nystroem
X_test_nystroem = nystroem.transform(X_test)

# Prédiction sur les données de test
Y_test_pred = KRregressor_nys.predict(X_test_nystroem)
```

```
# Calcul de l'erreur quadratique moyenne sur les données de test
rmse_test = np.sqrt(mean_squared_error(Y_test, Y_test_pred))

# Affichage des résultats
print("Performance du modèle sur la base d'apprentissage :")
print("Erreur quadratique moyenne : {:.2f}".format(rmse_train))
print('\n')
print("Performance du modèle sur la base de test :")
print("Erreur quadratique moyenne : {:.2f}".format(rmse_test))
```

```
Performance du modèle sur la base d'apprentissage :
Erreur quadratique moyenne : 218868.57


Performance du modèle sur la base de test :
Erreur quadratique moyenne : 187413.39
```

Les résultats sont moins bons avec l'approximation, ce qui est attendu et le temps de calcul est est même plus grand ce qui est étonnant (on regarde le temps d'exécution des cellules de code).

0.6 Comparaison des modèles

Nous allons maintenant nous intéresser à une comparaison détaillée des modèles.

Premièrment, il est intéressant d'observer que pour les modèles de régression linéaire, introduire de la régularisation n'améliore pas la prédiction en terme d'erreur quadratique moyenne, là où pour les modèles non linéaire Random Forest et Kernel Ridge, la prédiction est améliorée. Cela peut vouloir dire que : - Le jeu de données est assez propre et peu bruité - La forme intrinsèque d'un modèle linéaire ne permet pas de faire mieux que ce qui est obtenu et introduire de la régularisation n'améliore donc pas la prédiction

Choix du nombre de pli : Nous avons utilisé la source : https://machinelearningmastery.com/k-fold-cross-validation/ Nous avons choisi 10 plis car cette valeur est montrée efficace (empiriquement) et conseillée "par défaut". Notre jeu de données est assez grand pour que cette valeur ait du sens, il y a assez de données dans les 9 plis pour entrainer notre modèle.

[221]:
```
X = df.loc[:, ~df.columns.isin(['id','price'])]
Y = df['price']

# Ensemble des erreurs pour les différents modèles
RF_errors = []
lasso_errors = []
ridge_errors = []
KRR_errors = []

# Mise en place des plis
kfold = KFold(n_splits=10, shuffle=True, random_state=7)
for train_index, test_index in kfold.split(X, Y):
    X_train_CV = [X.iloc[i] for i in train_index]
```

```
    X_test_CV = [X.iloc[i] for i in test_index]
    Y_train_CV = [Y.iloc[i] for i in train_index]
    Y_test_CV = [Y.iloc[i] for i in test_index]

    RFregressor.fit(X_train_CV, Y_train_CV)
    Y_test_pred_RF = RFregressor.predict(X_test_CV)

    lassoreg.fit(X_train_CV, Y_train_CV)
    Y_test_pred_lasso = lassoreg.predict(X_test_CV)

    ridgereg.fit(X_train_CV, Y_train_CV)
    Y_test_pred_ridge = ridgereg.predict(X_test_CV)

    KRregressor.fit(X_train_CV, Y_train_CV)
    Y_test_pred_KRR = KRregressor.predict(X_test_CV)

    for i in range(len(Y_test_CV)):
        Y_test = Y_test_CV[i]
        RF_errors.append(Y_test_pred_RF[i]-Y_test)
        lasso_errors.append(Y_test_pred_lasso[i]-Y_test)
        ridge_errors.append(Y_test_pred_ridge[i]-Y_test)
        KRR_errors.append(Y_test_pred_KRR[i]-Y_test)
```

[222]:
```
RF_errors = np.array(RF_errors)
lasso_errors = np.array(lasso_errors)
ridge_errors = np.array(ridge_errors)
KRR_errors = np.array(KRR_errors)

# summary of errors arrays
print('RF_errors: mean=%.3f stdv=%.3f' % (np.mean(RF_errors), np.
 ↪std(RF_errors)))
print('lasso_errors: mean=%.3f stdv=%.3f' % (np.mean(lasso_errors), np.
 ↪std(lasso_errors)))
print('ridge_errors: mean=%.3f stdv=%.3f' % (np.mean(ridge_errors), np.
 ↪std(ridge_errors)))
print('KRR_errors: mean=%.3f stdv=%.3f' % (np.mean(KRR_errors), np.
 ↪std(KRR_errors)))
```

```
RF_errors: mean=-484.946 stdv=127218.182
lasso_errors: mean=-1.864 stdv=200231.092
ridge_errors: mean=-1.863 stdv=200231.067
KRR_errors: mean=-539436.173 stdv=367578.917
```

[223]:
```
fig = plt.figure(figsize =(10, 10))

boxplot_dict = {'RF':RF_errors, 'Lasso':lasso_errors, 'Ridge':ridge_errors,␣
 ↪'KRR':KRR_errors}
```

```
# Creating plot
plt.boxplot(boxplot_dict.values(), labels = boxplot_dict.keys())

# show plot
plt.show()
```

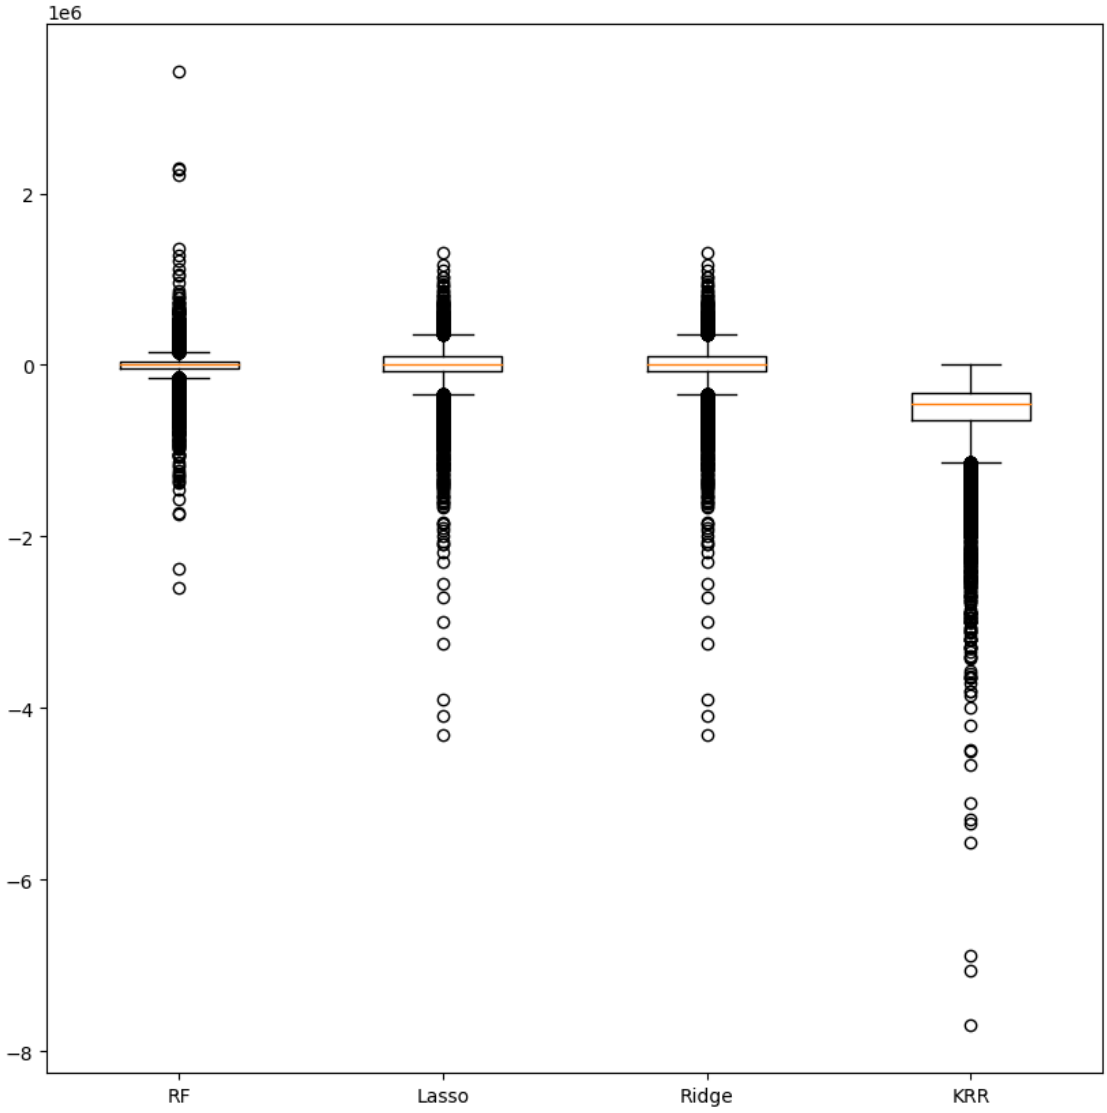

Premièrement, on constate que les régressions ridge et lasso ont des résultats égaux en terme de performance de prédiction. De plus, on constate que RandomForest a une erreur systématique en moyenne plus grande par rapport à ridge et lasso (-600 contre -20) mais c'est tout à fait négligeable considérant les ordres de grandeur du problème. A l'inverse, on constate que l'écart-type des erreurs est plus faible pour RandomForest que pour ridge et lasso (donc la variance également). Cependant, considérant les ordres de grandeurs du problème, un écart-type de 200 000€ pour ridge et lasso reste convenable, mais RandomForest est encore meilleur. La Kernel Ridge regression quant à elle

semblait meilleur que les régressions linéaires Ridge et Lasso sur son jeu d'entraînement mais avec le validation croisée, on se rend compte que ce modèle commet une grande erreur systématique et a un écart-type bien plus grand. Ce modèle n'est donc pas à garder. Finalement, le modèle le plus intéressant à utiliser est donc RandomForest.